1 Sortieren

1.1 Einführung - Das Sortierproblem

Definition — Das Sortierproblem Ausgangspunkt:

$$\boxed{D_1 \mid D_2 \mid \cdots \mid D_n}$$

Abbildung 1: Folge von Datensätzen D_1, D_2, \cdots, D_n

Ziel: Datensätze so anzuordnen, dass die Schlüsselwerte sukzessive ansteigen (oder absteigen) **Bedingung**: Schlüssel(werte) müssen vergleichbar sein

• zu sortierende Elemente heiSSen auch Schlüssel(werte)

Durchführung

- **Eingabe**: Sequenz von Schlüsselwerten $\{a_1, a_2, \dots, a_n\}$
- Eingabe ist eine Instanz des Sortierproblems
- Ausgabe: Permutation $\{a_1', a_2', \dots, a_n'\}$ derselben Folge mit Eigenschaft $a_1' \leq \dots \leq a_n'$
- Algorithmus ist **korrekt**, wenn dieser das Problem für alle Instanzen löst

1.2 Arrays

Definition – Array Reihung (Feld) fester Länge von Daten des gleichen Typs

Abbildung 2: beispielhafte Darstellung eines Arrays

- ABezeichnung des Arrays mit dem Namen " $A^{\prime\prime}$
- A[i] Zugiff auf das (i+1)-te Element des Arrays

Beispiel:

$$A[2] = 17$$

⇒ Arrays erlauben effizienten Zugriff auf Elemente: konstanter Aufwand

1.3 Exkurs: Totale Ordnung

Definition – Totale Ordnung Sei M eine nicht leere Menge und $\leq \subseteq M \times M$ eine binäre Relation auf M. Das Paar (M, \leq) heiSSt genau dann eine totale Relation auf der Menge M, wenn folgende Eigenschaften erfüllt sind:

- Reflexivität: $\forall x \in M : x \leq x$
- Transitivität: $\forall x, y, z \in M : x \leq y \land y \leq z \Rightarrow x \leq z$
- Antisymmetrie: $\forall x, y \in M : x \leq y \land y \leq x \Rightarrow x = y$
- Totalität: $\forall x, y \in M : x \leq y \lor y \leq x$

Beispiele

- \leq Ordnung auf natürlichen Zahlen
- Lexikographische Ordnung \leq_{lex} ist eine totale Ordnung

1.4 Vergleichskriterien von Suchalgorithmen

Berechnungsaufwand

• O(n)

Effizienz

• Best Case vs. Average Case vs Worst Case

Speicherbedarf

- in-Place (in situ): zusätzlicher Speicher von der EingabegröSSe unabhängig
- out-of-place: Speichermehrbedarf von EingabegröSSe abhängig

Stabilität

• stabile Verfahren verändern die Reihenfolge von äquivalenten Elementen nicht

Anwendung als Auswahlfaktor

- Hauptoperationen beim Sortieren: Vergleichen und Vertauschen
- Anwendung spielt eine enorme Rolle:
 - Verfahren mit vielen Vertauschungen und wenig Vergleichen, wenn Vergleichen teuer
 - Verfahren mit wenig Vertauschungen und vielen Vergleichen, wenn Umsortieren teuer

1.5 Analyse von Algorithmen (I)

Schleifeninvariante (SIV):

- Sonderform der Invariante
- Am Anfang/Ende jedes Schleifendurchlaufs und vor/nach jedem Schleifendurchlauf gültig
- Wird zur Feststellung der Korrektheit von Algorithmen verwendet
- Eigenschaften:

Initialisierung Invariante ist vor jeder Iteration wahr

Fortsetzung Wenn SIV vor der Schleife wahr ist, dann auch bis Beginn der nächsten Iteration

Terminierung SIV liefert bei Schleifenabbruch, helfende Eigenschaft für Korrektheit

• Beispiel für Umsetzung: Insertion Sort - SIV

Laufzeitanalyse:

- Aufstellung der Kosten und Durchführungsanzahl für jede Zeile des Quelltextes
- Beachte: Bei Schleifen wird auch der Aufruf gezählt, der den Abbruch einleitet
- Beispiel für Umsetzung: Insertion Sort Laufzeit
- Zusätzliche Überprüfung des Best Case, Worst Case und Average Case

Effizienz von Algorithmen:

Effizienzfaktoren

- Rechenzeit (Anzahl der Einzelschritte)
- Kommunikationsaufwand
- Speicherplatzbedarf
- Zugriffe auf Speicher

Laufzeitfaktoren

- Länge der Eingabe
- Implementierung der Basisoperationen
- Takt der CPU

1.6 Analyse von Algorithmen (II)

Komplexität:

- ullet Abstrakte Rechenzeit T(n) ist abhängig von den Eingabedaten
- Übliche Betrachtungsweise der Rechenzeit ist asymptotische Betrachtung

Asymptotik:

- Annäherung an einer sich ins Unendliche verlaufende Kurve
- z.B.: $f(x) = \frac{1}{x} + x$ | Asymptote: $g(x) = x \mid (\frac{1}{x} \text{ läuft gegen Null})$

Asymptotische Komplexität:

- Abschätzung des zeitlichen Aufwands eines Algorithmus in Abhängigkeit einer Eingabe
- \bullet Beispiel für Umsetzung: Insertion Sort Laufzeit Θ

Asymptotische Notation:

- Betrachtung der Laufzeit T(n) für sehr große Eingaben $n \in \mathbb{N}$
- Komplexität ist unabhängig von konstanten Faktoren und Summanden
- Nicht berücksichtigt: Rechnergeschwindigkeit / Initialisierungsaufwände
- Komplexitätsmessung via Funktionsklasse ausreichend
 - Verhalten des Algorithmus für große Problemgrößen
 - Veränderung der Laufzeit bei Verdopplung der Problemgröße

Gründe für die Nutzung der theoretischen Betrachtung statt der Messung der Laufzeit

Vergleichbarkeit

- Laufzeit abhängig von konkreter Implementierung und System
- Theoretische Betrachung ist frei von Abhängigkeiten und Seiteneffekten
- Theoretische Betrachtung lässt direkte Vergleichbarkeit zu

Aufwand

- Wieviele Testreihen?
- In welcher Umgebung?
- Messen führt in der Ausführung zu hohem, praktischen Aufwand

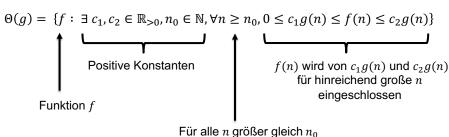
Komplexitätsfunktion

- Wachstumsverhalten ausreichend
- Praktische Evaluation mit Zeiten nur für Auswahl von Systemen möglich
- Theoretischer Vergleich (Funktionsklassen) hat ähnlichen Erkenntnisgewinn

1.7 Analyse von Algorithmen (III)

⊖-Notation

- \bullet Θ -Notation beschränkt eine Funktion asymptotisch von oben und unten
- Funktionen $f, g: \mathbb{N} \to \mathbb{R}_{>0}$ (N: Eingabelänge, \mathbb{R} : Zeit)



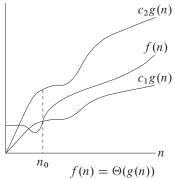


Abbildung 3: Veranschaulichung Θ-Notation

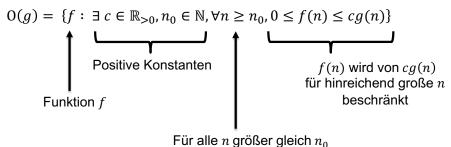
- $\bullet \ \Theta(g)$ enthält alle f, die genauso schnell wachsen wie g
- Schreibweise: $f \in \Theta(g)$ (korrekt), manchmal auch $f = \Theta(g)$
- g(n) ist eine asymptotisch scharfe Schranke von f(n)
- $f(n) = \Theta(g(n))$ gilt, wenn f(n) = O(g(n)) und $f(n) = \Omega(g(n))$ erfüllt sind
- z.B.: $f(n) = \frac{1}{2}n^2 3n \mid f(n) \in \Theta(n^2)$?
- Aus $\Theta(n^2)$ folgt, dass $g(n) = n^2$

• Vorgehen:

- Finden eines n_0 und c_1, c_2 , sodass
- $-c_1 * g(n) \le f(n) \le c_2 * g(n)$ erfüllt ist
- Konkret: $c_1 * n^2 \le \frac{1}{2}n^2 3n \le c_2 * n^2$
- Division durch n^2 : $c_1 \leq \frac{1}{2} \frac{3}{n} \leq c_2$
- Ab n=7 positives Ergebnis: $0,0714\mid n_0=7$
- Deswegen setzen wir $c_1 = \frac{1}{14}$
- Für $n \to \infty : 0,5 \mid c_2 = 0,5$
- Natürlich auch andere Konstanten möglich

O-Notation

 \bullet $\mathcal{O}\textsc{-Notation}$ beschränkt eine Funktion asymptotisch von oben



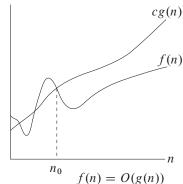


Abbildung 4: Veranschaulichung \mathcal{O} -Notation

- O(g) enthält alle f, die höchstens so schnell wie g wachsen
- Schreibweise: $f = \mathcal{O}(g)$
- $f(n) = \Theta(g) \to f(n) = \mathcal{O}(g) \mid \Theta(g(n)) \subseteq \mathcal{O}(g(n))$
- Ist f in der Menge $\Theta(g)$, dann auch in der Menge $\mathcal{O}(g)$
- z.B.: $f(n) = n + 2 | f(n) = \mathcal{O}(n)$?
- Ja f(n) ist Teil von $\mathcal{O}(n)$ für z.B. c=2 und $n_0=2$

O-Notation Rechenregeln

Konstanten • $f(n) = a \text{ mit } a \in \mathbb{R} \text{ konstante Funktion} \rightarrow f(n) = O(1)$

• z.B. $3 \in O(1)$

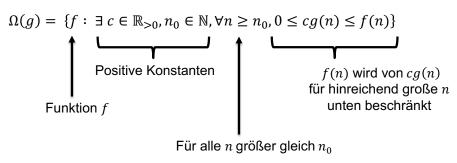
Skalare Multiplikation $\bullet \ f = O(g) \ \mathrm{und} \ a \in \mathbb{R} \to a * f = O(g)$

Addition • $f_1 = O(g_1)$ und $f_2 = O(g_2) \to f_1 + f_2 = O(\max\{g_1, g_2\})$

Multiplikation • $f_1 = O(g_1)$ und $f_1 = O(g_2) \rightarrow f_1 * f_2 = O(g_1 * g_2)$

Ω -Notation

 \bullet $\Omega\textsc{-Notation}$ beschränkt eine Funktion asymptotisch von unten



f(n) cg(n) n_0 $f(n) = \Omega(g(n))$

Abbildung 5: Veranschaulichung

- \bullet Ω -Notation enthält alle f, die mindestens so schnell wie g wachsen
- Schreibweise: $f = \Omega(g)$

Komplexitätsklassen

Klasse	Bezeichnung	Beispiel
$\Theta(1)$	Konstant	Einzeloperation
$\Theta(\log n)$	Logarithmisch	Binäre Suche
$\Theta(n)$	Linear	Sequentielle Suche
$\Theta(n\log n)$	Quasilinear	Sortieren eines Arrays
$\Theta(n^2)$	Quadratisch	Matrixaddition
$\Theta(n^3)$	Kubisch	Matrixmultiplikation
$\Theta(n^k)$	Polynomiell	
$\Theta(2^n)$	Exponentiell	$Travelling\text{-}Salesman^*$
$\Theta(n!)$	Faktoriell	Permutationen

Tabelle 1: Komplexitätsklassen (n= Länge der Eingabe)

EingabegröSSe n	$\log_{10} n$	n	n^2	n^3	2^n
10	1μ s	$10 \mu \text{s}$	$100 \mu \text{s}$	1ms	$\sim 1 \text{ ms}$
100	2μ s	$100 \mu \mathrm{s}$	10ms	1s	$\sim 4\times 10^{16}~{\rm y}$
1000	3μ s	1ms	1s	16min 40s	?
10000	4μ s	10ms	1min 40s	$\sim 11,5 \mathrm{d}$?
100000	$5\mu s$	100ms	2h 64min 40s	$\sim 31,7\mathrm{y}$?

Tabelle 2: Komplexitätsklassen-Ausführungsdauer, falls eine Operation n genau $1\mu s$ dauert

Es gilt: $\log(n) < \sqrt{n} < n < n \cdot \log(n) < n^2 < n! < 2^n < n^n$

Asymptotische Notationen in Gleichungen

- $2n^2 + 3n + 1 = 2n^2 + \Theta(n)$
- $\Theta(n)$ fungiert hier als Platzhalter für eine beliebige Funktion f(n) aus $\Theta(n)$
- z.B.: f(n) = 3n + 1

o-Notation

- o-Notation stellt eine echte obere Schranke dar
- Ausschlaggebend ist, dass es für alle $c \in \mathbb{R}_{>0}$ gelten muss
- Außerdem < statt \le
- z.B.: $2n = o(n^2)$ und $2n^2 \neq o(n^2)$ $o(g) = \{ f : \forall c \in \mathbb{R}_{>0}, \exists n_0 \in \mathbb{N}, \forall n \ge n_0, 0 \le f(n) < cg(n) \}$

Gilt für **alle** Konstanten c>0. In $\mathcal{O}\text{-Notation}$ gilt es für eine Konstante c>0

$\omega ext{-Notation}$

- \bullet $\,\omega\textsc{-Notation}$ stellt eine echte untere Schranke dar
- Ausschlaggebend ist, dass es für alle $c \in \mathbb{R} > 0$ gelten muss
- Außerdem > statt \ge
- z.B.: $\frac{n^2}{2} = \omega(n)$ und $\frac{n^2}{2} \neq \omega(n^2)$ $\omega(g) = \{f : \forall c \in \mathbb{R}_{>0}, \exists n_0 \in \mathbb{N} \forall n \geq n_0, 0 \leq cg(n) < f(n)\}$

1.8 Insertion Sort (Sortieren durch Einfügen)

Idee - Insertion-Sort

- Halte die linke Teilfolge sortiert
- Füge nächsten Schlüsselwert hinzu, indem es an die korrekte Position eingefügt wird
- Wiederhole den Vorgang bis Teilfolge aus der gesamten Liste besteht

Code

```
Insertion-Sort(A)

FOR j = 1 TO A.length - 1
key = A[j]
// Füge A[j] in die sortierte Sequenz A[0...j-1] ein
i = j - 1
WHILE i >= 0 and A[i] > key
A[i + 1] = A[i]
i = i - 1
A[i + 1] = key
```

Schleifeninvariante von Insertion Sort

• Zu Beginn jeder Iteration der for-Schleife besteht die Teilfolge A[0...j-1] aus den Elementen der ursprünglichen Teilfolge A[0...j-1] enthaltenen Elementen, allerdings in sortierter Reihenfolge.

Korrektheit von Insertion Sort

Initialisierung Beginn mit j=1, also Teilfeld A[0...j-1] besteht nur aus einem Element A[0]. Dies ist auch das ursprüngliche Element und Teilfeld ist sortiert.

Fortsetzung Zu zeigen ist, dass die Invariante bei jeder Iteration erhalten bleibt. Ausführungsblock der for-Schleife sorgt dafür, dass A[j-1], A[j-2],... je um Stelle nach rechts geschoben werden bis A[j] korrekt eingefügt wurde. Teilfeld A[0...j] besteht aus ursprünglichen Elementen und ist sortiert. Inkrementieren von j erhält die Invariante.

Terminierung Abbruchbedingung der for-Schleife, wenn j > A.length - 1. Jede Iteration erhöht j. Dann bei Abbruch ist j = n und einsetzen in Invariante liefert das Teilfeld A[0...n-1] welches aus den ursprünglichen Elementen besteht und sortiert ist. Teilfeld ist gesamtes Feld.

⇒ Algorithmus Insertion Sort arbeitet damit korrekt.

Laufzeitanalyse von Insertion Sort

Zeile	Kosten	Anzahl
1	c_1	n
2	c_2	n-1
3	0	n-1
4	c_4	n-1
5	c_5	$\sum_{j=1}^{n-1} t_j$
6	c_6	$\sum_{j=1}^{n-1} (t_j - 1)$
7	c_7	$\sum_{j=1}^{n-1} (t_j - 1)$
8	c_8	n-1

- Festlegung der Laufzeit für jede Zeile
- $\bullet\,$ Jede Zeile besitzt gewissen Kosten c_i
- $\bullet\,$ Jede Zeile wird x mal durchgeführt
- Laufzeit = Anzahl * Kosten jeder Zeile
- Schleifen: Abbruchüberprüfung zählt auch
- t_i : Anzahl der Abfragen der While-Schleife
- Laufzeit: $T(n) = c_1 n + c_2 (n-1) + c_4 (n-1) + c_5 \sum_{j=1}^{n-1} t_j + c_6 \sum_{j=1}^{n-1} (t_j 1) + c_7 \sum_{j=1}^{n-1} (t_j 1) + c_8 (n-1)$

Warum n in Zeile 1?

- Die Überprüfung der Fortführungsbedingung beinhaltet auch die letze Überprüfung
- Quasi die Überprüfung, durch die die Schleife abbricht

Warum $\sum_{j=1}^{n-1}$ in Zeile 5?

- $\bullet\,$ Aufsummierung aller einzelnen t_j über die Anzahl der Schleifendurchläufe
- $\bullet\,$ Diese ist allerdings n-1 und nicht n, da die Abbruchüberprüfung dort auch enthalten ist

Warum $t_j - 1$ in Zeile 6?

- $\bullet\,$ Selbes Argument wie oben, bei t_j ist die Abbruchüberprüfung enthalten
- $\bullet\,$ Deswegen wird die while-Schleife nur t_j-1 -mal ausgeführt

Best Case

- zu sortierendes Feld ist bereits sortiert
- ullet t_j wird dadurch zu 1, da die While-Schleife immer nur einmal prüft (Abbruch)
- Die zwei Zeilen innerhalb der While-Schleife werden nie ausgeführt
- \bullet Durch Umformen ergibt sich, dass die Laufzeit eine lineare Funktion in n ist

Worst Case

- zu sortierendes Feld ist umgekehrt sortiert
- t_j wird dadurch zu j+1, da die While-Schleife immer die gesamte Länge prüft
- Durch Umformen ergibt sich, dass die Laufzeit eine quadratische Funktion in n ist (n^2)

Average Case

- im Mittel gut gemischt
- t_j wird dadurch zu j/2
- Die Laufzeit bleibt aber eine quadratische Funktion in n (n^2)

Asymptotische Laufzeitbetrachtung ⊖

- T(n) lässt sich als quadratische Funktion $an^2 + bn + c$ betrachten
- \bullet Terme niedriger Ordnung sind für große n irrelevant
- Deswegen Vereinfachung zu n^2 und damit $\Theta(n^2)$

1.9 Bubble Sort

Idee - Bubble Sort

- Vergleiche Paare von benachbarten Schlüsselwerten
- Tausche das Paar, falls rechter Schlüsselwert kleiner als linker

Code

Analyse von Bubble Sort

Anzahl der Vergleiche

- Es werden stets alle Elemente der Teilfolge miteinander verglichen
- Unabhängig von der Vorsortierung sind Worst und Best Case identisch

Anzahl der Vertauschungen

- Best Case: 0 Vertauschungen
- Worst Case: $\frac{n^2-n}{2}$ Vertauschungen

Komplexität

- ullet Best Case: $\Theta(n)$
- Average Case: $\Theta(n^2)$
- Worst Case: $\Theta(n^2)$

1.10 Selection Sort

Idee – Selection Sort • Sortieren durch direktes Auswählen

- MinSort: "wähle kleines Element in Array und tausche es nach vorne"
- MaxSort: "wähle gröSStes Element in Array und tausche es nach vorne"

Code (MinSort)

1.11 Divide-And-Conquer Prinzip

Idee - Divide-And-Conquer

Zerlege das Problem und löse es direkt oder zerlege es weiter:

Divide

- Teile das Problem in mehrere Teilprobleme auf
- Teilprobleme sind Instanzen des gleichen Problems

Conquer

- Beherrsche die Teilprobleme rekursiv
- Falls Teilprobleme klein genug, löse sie auf direktem Weg

Combine

- Vereine die Lösungen der Teilprobleme zu Lösung des ursprünglichen Problems
- Anderer Ansatz im Gegensatz zu z.B. InsertionSort (inkrementelle Herangehensweise)
- Laufzeit ist im schlechtesten Fall immer noch besser als InsertionSort

1.12 Merge Sort

Idee - Merge Sort

- Divide: Teile die Folge aus n Elementen in zwei Teilfolgen von je $\frac{n}{2}$ Elemente auf
- Conquer: Sortiere die zwei Teilfolgen rekursiv mithilfe von MergeSort
- Combine: Vereinige die zwei sortierten Teilfolgen, um die sortierte Lösung zu erzeugen

Code

```
MERGE(A,p,q,r)
   n_1 = q - p + 1
   n_2 = r - q
   Let L[0...n_1] and R[0...n_2] be new arrays
   FOR i = 0 TO n_1 - 1 // Auffüllen der neu erstellten Arrays
     L[i] = A[p + i]
   FOR j = 0 TO n_2 - 1
     R[j] = A[q + j + 1]
   L[n_1] = \infty // Einfügen des Sentinel-Wertes
   R[n_2] = \infty
10
   i = 0
   j = 0
   FOR k = p TO r // Eintragweiser Vergleich der Elemente
     IF L[i] \leq R[j]
14
          A[k] = L[i] // Sortiertes Zurückschreiben in Original-Array
          i = i + 1
     ELSE
          A[k] = R[j]
          j = j + 1
18
```

(Teilarrays werden nicht parallel bearbeitet)

Korrektheit von MergeSort

Schleifeninvariante Zu Beginn jeder Iteration der for-Schleife (Letztes for in Methode MERGE) enthält das Teilfeld A[p...k-1] die k-p kleinsten Elemente aus $L[0...n_1]$ und $R[0...n_2]$ in sortierter Reihenfolge. Weiter sind L[i] und R[i] die kleinsten Elemente ihrer Arrays, die noch nicht zurück kopiert wurden.

Initialisierung Vor der ersten Iteration gilt k=p. Daher ist A[p...k-1] leer und enthält 0 kleinste Elemente von L und R. Wegen i=j=0 sind L[i] und R[i] die kleinsten Elemente ihrer Arrays, die noch nicht zurück kopiert wurden.

Fortsetzung Müssen zeigen, dass Schleifeninvariante erhalten bleibt. Dafür nehmen wir an, dass L[i] ≤ R[j]. Dann ist L[i] kleinstes Element, welches noch nicht zurück kopiert wurde. Da Array A[p...k-1] die k-p kleinsten Elemente enthält, wird der Array A[p...k] die k-p+1 kleinsten Elemente enthalten, nachdem der Wert nach der Durchführung von A[k]=L[i] kopiert wurde. Die Erhöhung der Variablen k und i stellt die Schleifeninvariante für die nächste Iteration wieder her. Wenn L[i]>R[j] dann analoges Argument in der ELSE-Anweisung.

Terminierung Beim Abbruch gilt k=r+1. Durch die Schleifeninvariante enthält A[p...r] die kleinste Elemente von $L[0...n_1]$ und $R[0...n_2]$ in sortierter Reihenfolge. Alle Elemente auSSer der Sentinels wurden komplett zurück kopiert. MergeSort ist auSSerdem ein stabiler Algorithmus.

Analyse von MergeSort

Ziel Bestimme Rekursionsgleichung für Laufzeit T(n) von n Zahlen im schlechtesten Fall

Divide Berechnung der Mitte des Feldes: Konstante Zeit $\Theta(1)$

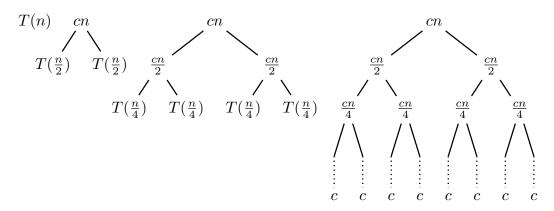
Conquer Rekursives Lösen von zwei Teilproblemen der Größe $\frac{n}{2}$: Laufzeit von 2 $T(\frac{n}{2})$

Combine MERGE auf einem Teilfeld der Länge n: Lineare Zeit $\Theta(n)$

$$T(n) = \begin{cases} \Theta(1) & \text{falls } n = 1 \\ 2 \ T(\frac{n}{2}) + \Theta(n) & \text{falls } n > 1 \end{cases}$$

• Lösen der Rekursionsgleichung mithilfe eines Rekursionsbaums

$$T(n) = \begin{cases} c & \text{falls } n = 1, \\ 2T(\frac{n}{2}) + cn & \text{falls } n > 1 \end{cases}$$



- Verwenden der Konstante c statt $\Theta(1)$
- -cn stellt den Aufwand an der ersten Ebene dar
- Der addierte Aufwand jeder Stufe (aller Knoten) ist auch cn
- Die Azahl der Ebenen lässt sich mithilfe von lg(n) + 1 bestimmen (2-er Logarithmus)
- Damit ergibt sich für die Laufzeit: $cn \cdot lg(n) + cn$
- Für $\lim_{n\to\infty}$ wird diese zu $n\cdot lg(n)$
- Laufzeit beträgt damit $\Theta(n \cdot lg(n))$
- Laufzeit von MergeSort ist in jedem Fall gleich

1.13 Quicksort

Idee - Quicksort

Pivotelement Wahl eines Pivotelement x aus dem Array (=Mittelsäule bei Sortierung)

Divide Zerlege den Array A[p...r] in zwei Teilarrays A[p...q-1] und A[q+1...r], sodass jedes Element von A[p...q-1] kleiner oder gleich A[q] ist, welches wiederum kleiner oder gleich jedem Element von A[q+1...r] ist. Berechnen Sie den Index q als Teil vom Partition Algorithmus.

Conquer Sortieren beider Teilarrays A[p...q-1] und A[q+1...r] durch rekursiven Aufruf von Quicksort.

Combine Da die Teilarrays bereits sortiert sind, ist keine weitere Arbeit nötig um diese zu vereinigen. A[p...r] ist nun sortiert.

Code

```
QUICKSORT(A,p,r)

IF p < r // Überprüfung, ob Teilarray leer ist

q = PARTITION(A,p,r)

QUICKSORT(A,p,q-1)

QUICKSORT(A,q+1,r)
```

(Teilarrays werden nicht parallel bearbeitet)

Korrektheit von Quicksort

Schleifeninvariante Zu Beginn jeder Iteration der for-Schleife gilt für den Arrayindex k folgendes:

- 1. Ist $p \le k \le i$, so gilt $A[k] \le x$
- 2. Ist $i + 1 \le k \le j 1$, so gilt A[k] > x
- 3. Ist k = r, so gilt A[k] = x
- Initialisierung Vor der ersten Iteration gilt i=p-1 und j=p. Da es keine Werte zwischen p und i gibt und es auch keine Werte zwischen i+1 und j-1 gibt, sind die ersten beiden Eigenschaften trivial erfüllt. Die Zuweisung in x = A[r] sorgt für die Erfüllung der dritten Eigenschaft.
 - Fortsetzung Zwei mögliche Fälle durch IF A[j] \leq x. Wenn A[j] > x, dann inkrementiert die Schleife nur den Index j. Dann gilt Bedingung 2 für A[j-1] und alle anderen Einträge bleiben unverändert. Wenn A[j] \leq x, dann wird Index i inkrementiert und die Einträge A[i] und A[j] getauscht und schlieSSlich der Index j erhöht. Wegen des Vertauschens gilt A[i] \leq x und Bedingung 1 ist erfüllt. Analog gilt A[j-1] > x, da das Element welches mit A[j-1] vertauscht wurde wegen der Invariante gerade gröSSer als x ist.
- Terminierung Bei der Terminierung gilt, dass j = r. Daher gilt, dass jeder Eintrag des Arrays zu einer der drei durch die Invariante beschriebenen Mengen gehört.

Performanz von Quicksort

- Abhängig von der Balanciertheit der Teilarrays
 - Definition Balanciert: ungefähr gleiche Anzahl an Elementen
 - Teilarrays balanciert: Laufzeit asymptotisch so schnell wie MergeSort
 - Teilarrays unbalanciert: Laufzeit kann so langsam wie InsertionSort laufen
- Zerlegung im schlechtesten Fall
 - Partition zerlegt Problem in ein Teilproblem mit n-1 Elementen und eins mit 0 Elementen
 - Unbalancierte Zerlegung mit Kosten $\Theta(n)$ zieht sich durch gesamte Rekursion
 - Aufruf auf Feld der Größe 0: $T() = \Theta(1)$
 - Laufzeit (rekursiv):

*
$$T(n) = T(n-1) + T(0) + \Theta(n) = T(n-1) + \Theta(n)$$

- * Insgesamt folgt: $T(n) = \Theta(n^2)$
- Zerlegung im besten Fall
 - Problem wird so balanciert wie möglich zerlegt
 - Zwei Teilprobleme mit maximaler GröSSe von $\frac{n}{2}$
 - Zerlegung kostet $\Theta(n)$
 - Laufzeit (rekursiv):
 - * $T(n) \leq 2T(\frac{n}{2}) + \Theta(n)$
 - * Laufzeit beträgt: O(n lq(n))
 - Solange die Aufteilung konstant bleibt, bleibt die Laufzeit $O(n \lg(n))$

1.14 Laufzeitanalyse von rekursiven Algorithmen

1.14.1 Analyse von Divide-And-Conquer Algorithmen

- \bullet T(n) ist Laufzeit eines Problems der GröSSe n
- \bullet Für kleines Problem benötigt die direkte Lösung eine konstante Zeit $\Theta(1)$
- Für sonstige n gilt:
 - Aufteilen eines Problems führt zu a Teilproblemen
 - Jedes dieser Teilprobleme hat die Grö
SSe $\frac{1}{b}$ der Grö SSe des ursprünglichen Problems
 - Lösen eines Teilproblems der GröSSe $\frac{n}{b}$: $T(\frac{n}{b})$
 - Lösen a solcher Probleme: $a T(\frac{n}{b})$
 - -D(n): Zeit um das Problem aufzuteilen (Divide)
 - -C(n): Zeit um Teillösungen zur Gesamtlösung zusammenzufügen (Combine)

$$T(n) = \begin{cases} \Theta(1) & \text{falls } n \le c \\ a \ T(\frac{n}{b}) + D(n) + C(n) & \text{sonst} \end{cases}$$

1.14.2 Subsitutionsmethode

- Idee: Erraten einer Schranke und Nutzen von Induktion zum Beweis der Korrektheit
- Ablauf:
 - 1. Rate die Form der Lösung (Scharfes Hinsehen oder kurze Eingaben ausprobieren/einsetzen)
 - 2. Anwendung von vollständiger Induktion zum Finden der Konstanten und Beweis der Lösung

Beispiel

Betrachten von MergeSort

• $T(1) \leq c$

•
$$T(n) \le T(\lfloor \frac{n}{2} \rfloor) + T(\lceil \frac{n}{2} \rceil) + cn$$

Ziel

Obere Abschätzung $T(n) \leq g(n)$ mit g(n) ist eine Funktion, die durch eine geschlossene Formel dargestellt werden kann.

Wir "raten": $T(n) \leq 4cn \ lg(n)$ und nehmen dies für alle n' < n an und zeigen es für n.

Induktion

- lg steht hier für log₂
- $n = 1: T(1) \le c$

•
$$n = 2$$
: $T(2) \le T(1) + T(1) + 2c$
 $\le 4c \le 8c$
 $T(2) = 4c * 2 lg(2) = 8c$

Hilfsbehauptungen

- (1): $\left\lfloor \frac{n}{2} \right\rfloor + \left\lceil \frac{n}{2} \right\rceil = n$
- (2): $\left| \frac{n}{2} \right| \le \frac{n}{2} \le \frac{2}{3}n$
- (3): $\log_c(\frac{a}{b}) = \log_c(a) \log_c(b)$
- (4): $\log_c(a*b) = \log_c(a) + \log_c(b)$

Induktionsschritt

• Annahme: n > 2 und sei Behauptung wahr für alle n' < n.

$$\begin{split} \mathrm{T(n)} & \leq T(\left\lfloor \frac{n}{2} \right\rfloor) + T(\left\lceil \frac{n}{2} \right\rceil) + cn \\ & \leq 4c \left\lfloor \frac{n}{2} \right\rfloor \, lg(\left\lfloor \frac{n}{2} \right\rfloor) + 4c \left\lceil \frac{n}{2} \right\rceil \, lg(\left\lceil \frac{n}{2} \right\rceil) + cn \\ \mathrm{(HB)} & \leq 4c \cdot lg(\frac{2}{3}n) \cdot \left(\left\lfloor \frac{n}{2} \right\rfloor + \left\lceil \frac{n}{2} \right\rceil + cn \\ & \leq 4c \cdot lg(\frac{2}{3}n) \cdot n + cn \\ \mathrm{(HB)} & \leq 4cn \cdot (lg(\frac{2}{3}) + lg(n)) + cn \\ & = 4cn \cdot lg(n) + 4cn \cdot lg(\frac{2}{3}) \\ & = 4cn \cdot lg(n) + cn(1 + 4 \cdot (lg(2) - lg(3))) \\ & \leq 4cn \cdot lg(n) \\ & \Rightarrow \Theta(n \ lg(n)) \end{split}$$

1.14.3 Rekursionsbaum

Idee - Rekursionsbaum

Stellen das Ineinander-Einsetzen als Baum dar und Analyse der Kosten. Ablauf:

- 1. Jeder Knoten stellt die Kosten eines Teilproblems dar
 - $\bullet\,$ Die Wurzel stellt die zu analysierenden Kosten T(n)dar
 - $\bullet\,$ Die Blätter stellen die Kosten der Basisfälle dar (z.B. T(0))
- 2. Berechnen der Kosten innerhalb jeder Ebene des Baums
- 3. Die Gesamtkosten sind die Summe über die Kosten aller Ebenen

Rekursionsbaum ist nützlich um Lösung für Subsitutionsmethode zu erraten

Beispiel

$$T(n) = 3T(\lfloor \frac{n}{4} \rfloor) + \Theta(n^2)$$

Vorüberlegungen

- $\Rightarrow T(n) = 3T(\frac{n}{4}) + cn^2 \ (c > 0)$
- Je Abstieg verringert sich die GröSSe des Problems um den Faktor 4.
- Erreichen der Randbedingung ist vonnöten, die Frage ist wann dies geschieht.
- GröSSe Teilproblem bei Level $i: \frac{n}{4^i}$
- Erreichen Teilproblem der Größe 1, wenn $\frac{n}{4^i} = 1$, d.h. wenn $i = log_4(n)$ \Rightarrow Baum hat also $\log_4 n + 1$ Ebenen

Kosten pro Ebene

- Jede Ebene hat 3-mal soviele Knoten wie darüber liegende
- Anzahl der Knoten in Tiefe i ist 3^i
- Kosten $c(\frac{n}{4^i})^2$, $i = 0, \dots, \log_4 n 1$
- Anzahl · Kosten = $3^i \cdot c(\frac{n}{4^i})^2 = (\frac{3}{16})^i \cdot cn^2$

Unterste Ebene

- $3^{\log_4(n)} = n\log_4(3)$ Knoten
- \bullet Jeder Knoten trägt T(1) Kosten bei
- Kosten unten: $n^{\log_4(3)} \cdot T(1) = \Theta(n^{\log_4(3)})$

Ebenen

Addiere alle Kosten aller
$$T(n) = cn^2 + \frac{3}{16}cn^2 + (\frac{3}{16})^2cn^2 + \ldots + (\frac{3}{16})^{\log_4 n - 1}cn^2 + \Theta(n^{\log_4(3)})$$

$$= \sum_{i=0}^{\log_4 n - 1} (\frac{3}{16})^icn^2 + \Theta(n^{\log_4^3})$$

$$= \frac{(\frac{3}{16}^{\log_4 n}) - 1}{\frac{3}{16} - 1} \cdot cn^2 + \Theta(n^{\log_4 3})$$

• Verwendung einer unendlichen fallenden geometrischen Reihe als obere Schranke:

$$\begin{split} T(n) &= \sum\nolimits_{i=0}^{-1} (\frac{3}{16})^i \cdot cn^2 + \Theta(n^{\log_4 3}) \\ &< \sum\nolimits_{i=0}^{\infty} (\frac{3}{16})^i \cdot cn^2 + \Theta(n^{\log_4 3}) \\ &= \frac{1}{1 - \frac{3}{16}} \cdot cn^2 + \Theta(n^{\log_4 3}) \\ &= \frac{16}{13} \cdot cn^2 + Theta(n^{\log_4 3}) = O(n^2) \end{split}$$

Jetzt

Zu zeigen
$$\exists d > 0 : T(n) \leq dn^2$$

Subsitutionsmethode

Induktionsanfang
$$T(n)=3\cdot T(\left\lfloor \frac{1}{4} \right\rfloor)+c\cdot 1^2$$

$$=3\cdot T(0)+c=c$$

$$\begin{split} \text{Induktionsschritt} \ \ T(n) &\leq 3 \cdot T(\left\lfloor \frac{n}{4} \right\rfloor) + cn^2 \\ &\leq 3 \cdot d(\left\lfloor \frac{n}{4} \right\rfloor)^2 + cn^2 \\ &\leq 3d(\frac{n}{4})^2 + cn^2 \\ &= \frac{3}{16}dn^2 + cn^2 \\ &\leq dn^2, \, \text{falls} \ d \geq \frac{16}{13}c \end{split}$$

1.14.4 Mastertheorem

Idee - Mastertheorem

Seien $a \ge 1$ und b > 1 Konstanten. Sei f(n) eine positive Funktion und T(n) über den nichtnegativen ganzen Zahlen über die Rekursionsgleichung $T(n) = a \ T(\frac{n}{b}) + f(n)$ defininiert, wobei wir $\frac{n}{b}$ so interpretieren, dass damit entweder $\left\lfloor \frac{n}{b} \right\rfloor$ oder $\left\lceil \frac{n}{b} \right\rceil$ gemeint ist. Dann besitzt T(n) die folgenden asymptotischen Schranken (a und b werden aus f(n) gelesen):

- 1. Gilt $f(n) = O(n^{\log_b(a-\epsilon)})$ für eine Konstante $\epsilon > 0$, dann $T(n) = \Theta(n^{\log_b(a)})$
- 2. Gilt $f(n) = \Theta(n^{\log_b(a)})$, dann gilt $T(n) = \Theta(n^{\log_b(a)} lg(n))$
- 3. Gilt $f(n) = \Omega(n^{\log_b(a+\epsilon)})$ für eine Konstante $\epsilon > 0$ und a $f(\frac{n}{b}) \le c$ f(n) für eine Konstante c < 1 und hinreichend groSSen n, dann ist $T(n) = \Theta(f(n))$

Erklärung

- In jedem der 3 Fälle wird die Funktion f(n) mit $n^{\log_b(a)}$ verglichen
 - 1. Wenn f(n) polynomial kleiner ist als $n^{\log_b(a)}$, dann $T(n) = \Theta(n^{\log_b(a)})$
 - 2. Wenn f(n) und $n^{\log_b(a)}$ die gleiche Größe haben, gilt $T(n) = \Theta(n^{\log_b(a)} lg(n))$
 - 3. Wenn f(n) polynomial gröSSer als $n^{\log_b(a)}$ und a $f(\frac{n}{b}) \le c$ f(n) erfüllt, dann $T(n) = \Theta(f(n))$
- (polynomial gröSSer/kleiner: um Faktor n^{ϵ} asymptotisch gröSSer/kleiner)

Nicht abgedeckte Fälle

- Wenn einer dieser Fälle eintritt, kann das Mastertheorem nicht angewendet werden
 - 1. Wenn f(n) kleiner ist als $n^{\log_b(a)}$, aber nicht polynomial kleiner
 - 2. Wenn f(n) größer ist als $n^{\log_b(a)}$, aber nicht polynomial größer
 - 3. Regularitätsbedingung $a f(\frac{n}{h}) \leq c f(n)$ wird nicht erfüllt
 - 4. a oder b sind nicht konstant (z.B. $a = 2^n$)

Beispiel

•
$$T(n) = 9T(\frac{n}{3}) + n$$

- $a = 9, b = 3, f(n) = n$
- $\log_b(a) = \log_3(9) = 2$
- $f(n) = n = O(n^{\log_b(a - \epsilon)})$
= $O(n^{2 - \epsilon})$
- Ist diese Gleichung für ein $\epsilon > 0$ erfüllt? $\Rightarrow \epsilon = 1$
- 1. Fall $\Rightarrow T(n) = \Theta(n^2)$
• $T(n) = T(\frac{2n}{3}) + 1$
- $a = 1, b = \frac{3}{2}, f(n) = 1$
- $\log_{\frac{3}{2}} 1 = 0$
- $f(n) = 1 = O(n^{\log_b(a)})$

$$-f(n) = 1 = O(n^{\log_b(a)})$$

$$= O(n^0)$$

$$= O(1)$$

– 2.Fall
$$\Rightarrow T(n) = \Theta(1 * lg(n)) = \Theta(lg(n))$$

$$\begin{split} \bullet \ T(n) &= 3(T\frac{n}{4}) + n \ lg(n) \\ &- a = 3, b = 4, f(n) = n \ lg(n) \\ &- n^{\log_b(a)} = n^{\log_4(3)} \leq n^{0.793} \\ &- \epsilon = 0.1 \ \text{im Folgenden} \\ &- f(n) = n \ lg(n) \geq n \geq n^{0.793 + 0.1} \geq n^{0.793} \end{split}$$

$$-f(n) = n \ lg(n) \ge n \ge n^{4n+6} \ge n^{4n+6}$$

$$-3.\text{Fall} \Rightarrow f(n) = \Omega(n^{\log_b(a+0.1)})$$

$$-af(\frac{n}{b}) = 3f(\frac{n}{4}) = 3(\frac{n}{4}) \ lg(\frac{n}{4}) \le \frac{3}{4}n \ lg(n)$$

– Damit ist auch die Randbedingung erfüllt und $T(n) = \Theta(n \ lg(n))$

Grundlegende Datenstrukturen Fortgeschrittene Datenstrukturen Randomisierte Datenstrukturen

Stacks Rot-Schwarz-Bäume Skip Lists

Stacks	Rot-Schwarz-Bäume	Skip Lists
Verkettete Listen	AVL-Bäume	Hash Tables
Queues	Splay-Bäume	Bloom-Filter
Bäume	Heaps	
Binäre Suchbäume	B-Bäume	

Tabelle 3: Übersicht Datenstrukturen