1 Sortieren

1.1 Einführung

Das Sortierproblem

• Ausgangspunkt: Folge von Datensätzen D_1, D_2, \cdots, D_n

$$D_1 D_2 \cdots D_n$$

- zu sortierende Elemente heißen auch Schlüssel(werte)
- Ziel: Datensätze so anzuordnen, dass die Schlüsselwerte sukzessive ansteigen (oder absteigen)
- Bedingung: Schlüssel(werte) müssen vergleichbar sein

Durchführung:

- Eingabe: Sequenz von Schlüsselwerten $\{a_1, a_2, \dots, a_n\}$
- Eingabe ist eine **Instanz** des Sortierproblems
- Ausgabe: Permutation $\{a_1',a_2',\dots,a_n'\}$ derselben Folge mit Eigenschaft $a_1'\leq \dots \leq a_n'$
- Algorithmus **korrekt**, wenn dieser das Problem für alle Instanzen löst

1.2 Arrays

Reihung (Feld) fester Länge von Daten des gleichen Typs

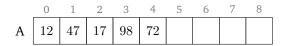


ABBILDUNG 1: beispielhafte Darstellung eines Arrays

- A: Bezeichnung des Arrays mit dem Namen "A"
- A[i]: Zugiff auf das (i + 1)-te Element des Arrays

Beispiel: A[2] = 17

⇒ Arrays erlauben effizienten Zugriff auf Elemente: konstanter Aufwand

1.3 Exkurs: Totale Ordnung

Sei M eine nicht leere Menge und $\leq \subseteq M \times M$ eine binäre Relation auf M.

Das Paar (M, \leq) heißt genau dann eine totale Relation auf der Menge M, wenn folgende Eigenschaften erfüllt sind:

- Reflexivität: $\forall x \in M : x \leq x$
- Transitivität: $\forall x,y,z\in M: x\leq y \land y\leq z \Rightarrow x\leq z$
- Antisymmetrie: $\forall x, y \in M : x \leq y \land y \leq x \Rightarrow x = y$
- Totalität: $\forall x, y \in M : x \leq y \lor y \leq x$

Beispiele:

- ullet \leq Ordnung auf natürlichen Zahlen
- Lexikographische Ordnung \leq_{lex} ist eine totale Ordnung

1.4 Vergleichskriterien von Suchalgorithmen

- Berechnungsaufwand: $\mathcal{O}(n)$
- Effizienz: Best Case vs. Average Case vs Worst Case
- · Speicherbedarf:
 - in-Place (in situ): zusätzlicher Speicher von der Eingabegröße unabhängig
 - out-of-place: Speichermehrbedarf von Eingabegröße abhängig
- Stabilität: stabile Verfahren verändern die Reihenfolge von äquivalenten Elementen nicht
- Anwendung als Auswahlfaktor:
 - Hauptoperationen beim Sortieren: Vergleichen und Vertauschen
 - Anwendung spielt eine enorme Rolle:
 - * Verfahren mit vielen Vertauschungen und wenig Vergleichen, wenn Vergleichen teuer
 - * Verfahren mit wenig Vertauschungen und vielen Vergleichen, wenn Umsortieren teuer

1.5 Analyse von Algorithmen (I)

• Schleifeninvariante (SIV):

- Sonderform der Invariante
- Am Anfang/Ende jedes Schleifendurchlaufs und vor/nach jedem Schleifendurchlauf gültig
- Wird zur Feststellung der Korrektheit von Algorithmen verwendet
- Eigenschaften:
 - * Initialisierung: Invariante ist vor jeder Iteration wahr
 - * Fortsetzung: Wenn SIV vor der Schleife wahr ist, dann auch bis Beginn der nächsten Iteration
 - * Terminierung: SIV liefert bei Schleifenabbruch, helfende Eigenschaft für Korrektheit
- Beispiel für Umsetzung: Insertion Sort SIV

· Laufzeitanalyse:

- Aufstellung der Kosten und Durchführungsanzahl für jede Zeile des Quelltextes
- Beachte: Bei Schleifen wird auch der Aufruf gezählt, der den Abbruch einleitet
- Beispiel für Umsetzung: Insertion Sort Laufzeit
- Zusätzliche Überprüfung des Best Case, Worst Case und Average Case

• Effizienz von Algorithmen:

- Effizienzfaktoren
 - * Rechenzeit (Anzahl der Einzelschritte)
 - * Kommunikationsaufwand
 - * Speicherplatzbedarf
 - * Zugriffe auf Speicher
- Laufzeit hängt von versch. Faktoren ab
 - * Länge der Eingabe
 - * Implementierung der Basisoperationen
 - * Takt der CPU

1.6 Analyse von Algorithmen (II)

Komplexität:

- Abstrakte Rechenzeit T(n) ist abhängig von den Eingabedaten
- Übliche Betrachtungsweise der Rechenzeit ist asymptotische Betrachtung

· Asymptotik:

- Annäherung an einer sich ins Unendliche verlaufende Kurve
- z.B.: $f(x) = \frac{1}{x} + x$ | Asymptote: g(x) = x | $(\frac{1}{x}$ läuft gegen Null)

• Asymptotische Komplexität:

- Abschätzung des zeitlichen Aufwands eines Algorithmus in Abhängigkeit einer Eingabe
- Beispiel für Umsetzung: Insertion Sort Laufzeit Θ

· Asymptotische Notation:

- Betrachtung der Laufzeit T(n) für sehr große Eingaben $n \in \mathbb{N}$
- Komplexität ist unabhängig von konstanten Faktoren und Summanden
- Nicht berücksichtigt: Rechnergeschwindigkeit / Initialisierungsaufwände
- Komplexitätsmessung via Funktionsklasse ausreichend
 - * Verhalten des Algorithmus für große Problemgrößen
 - * Veränderung der Laufzeit bei Verdopplung der Problemgröße

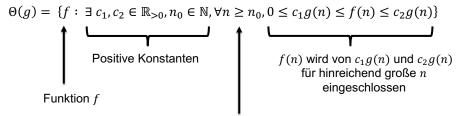
• Gründe für die Nutzung der theoretischen Betrachtung statt der Messung der Laufzeit

- Vergleichbarkeit
 - * Laufzeit abhängig von konkreter Implementierung und System
 - * Theoretische Betrachung ist frei von Abhängigkeiten und Seiteneffekten
 - * Theoretische Betrachtung lässt direkte Vergleichbarkeit zu
- Aufwand
 - * Wieviele Testreihen?
 - * In welcher Umgebung?
 - * Messen führt in der Ausführung zu hohem, praktischen Aufwand
- Komplexitätsfunktion
 - * Wachstumsverhalten ausreichend
 - * Praktische Evaluation mit Zeiten nur für Auswahl von Systemen möglich
 - * Theoretischer Vergleich (Funktionsklassen) hat ähnlichen Erkenntnisgewinn

1.7 Analyse von Algorithmen (III)

Θ-Notation

- $-\Theta$ -Notation beschränkt eine Funktion asymptotisch von oben und unten
- Funktionen $f,g:\mathbb{N}\to\mathbb{R}_{>0}$ (\mathbb{N} : Eingabelänge, \mathbb{R} : Zeit)



Für alle n größer gleich n_0

- $-\Theta(g)$ enthält alle f, die genauso schnell wachsen wie g
- Schreibweise: $f \in \Theta(g)$ (korrekt), manchmal auch $f = \Theta(g)$
- g(n) ist eine asymptotisch scharfe Schranke von f(n)
- $f(n) = \Theta(g(n))$ gilt, wenn f(n) = O(g(n)) und $f(n) = \Omega(g(n))$ erfüllt sind

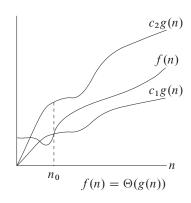
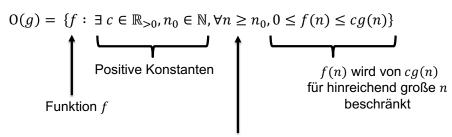


ABBILDUNG 2: Veranschaulichung

- * z.B.: $f(n) = \frac{1}{2}n^2 3n \mid f(n) \in \Theta(n^2)$?
- * Aus $\Theta(n^2)$ folgt, dass $g(n) = n^2$
- * Vorgehen:
 - · Finden eines n_0 und c_1, c_2 , sodass
 - $c_1 * g(n) \le f(n) \le c_2 * g(n)$ erfüllt ist
 - · Konkret: $c_1 * n^2 \le \frac{1}{2}n^2 3n \le c_2 * n^2$
 - · Division durch n^2 : $c_1 \leq \frac{1}{2} \frac{3}{n} \leq c_2$
 - · Ab n=7 positives Ergebnis: $0,0714 \mid n_0=7$
 - · Deswegen setzen wir $c_1 = \frac{1}{14}$
 - · Für $n \to \infty: 0,5 \mid c_2 = 0,5$
 - · Natürlich auch andere Konstanten möglich

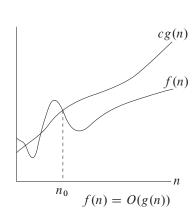
• O-Notation

- O-Notation beschränkt eine Funktion asymptotisch von oben



Für alle n größer gleich n_0

- O(g) enthält alle f, die höchstens so schnell wie g wachsen
- Schreibweise: f = O(g)
- $f(n) = \Theta(g) \rightarrow f(n) = O(g) \ | \ \Theta(g(n)) \subseteq O(g(n))$
- Ist f in der Menge $\Theta(g)$, dann auch in der Menge O(g)



* z.B.: $f(n) = n + 2 \mid f(n) = O(n)$?

* Ja f(n) ist Teil von O(n) für z.B. c=2 und $n_0=2$

ABBILDUNG 3: Veranschaulichung

• *O*-Notation Rechenregeln

- Konstanten:
 - * $f(n) = a \text{ mit } a \in \mathbb{R} \text{ konstante Funktion} \rightarrow f(n) = O(1)$
 - * z.B. $3 \in O(1)$
- Skalare Multiplikation:

*
$$f = O(g)$$
 und $a \in \mathbb{R} \to a * f = O(g)$

- Addition:

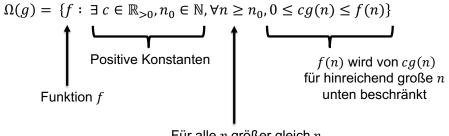
*
$$f_1 = O(g_1)$$
 und $f_2 = O(g_2) \rightarrow f_1 + f_2 = O(max\{g_1, g_2\})$

- Multiplikation:

*
$$f_1 = O(g_1)$$
 und $f_1 = O(g_2) \to f_1 * f_2 = O(g_1 * g_2)$

• Ω -Notation

– Ω -Notation beschränkt eine Funktion asymptotisch von unten



Für alle n größer gleich n_0

- Ω -Notation enthält alle f, die mindestens so schnell wie g wachsen
- Schreibweise: $f = \Omega(g)$

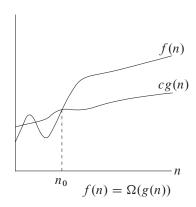


ABBILDUNG 4: Veranschaulichung

Komplexitätsklassen

– $\,n\,$ ist hier die Länge der Eingabe

Klasse	Bezeichnung	Beispiel	
0(1)	Konstant	Einzeloperation	
$\Theta(\log n)$	Logarithmisch	hmisch Binäre Suche	
$\Theta(n)$	Linear	Sequentielle Suche	
$\Theta(n \log n)$	Quasilinear	Sortieren eines Arrays	
$\Theta(n^2)$	Quadratisch	Matrixaddition	
$\Theta(n^3)$	Kubisch	Matrixmultiplikation	
$\Theta(n^k)$	Polynomiell		
$\Theta(2^n)$	Exponentiell	Travelling-Salesman*	
$\Theta(n!)$	Faktoriell	Permutationen	

– Ausführungsdauer, falls eine Operation n genau $1\mu s$ dauert

Eingabe- $$ größe n	$log_{10}n$	n	n^2	n^3	2 ⁿ
10	1µs	10µs	100µs	1ms	~1ms
100	2µs	100µs	10ms	1s	~4x10 ¹⁶ y
1000	3µs	1ms	1s	16min 40s	?
10000	4µs	10ms	1min 40s	~11,5d	?
100000	5µs	100ms	2h 46min 40s	~31,7y	?

• Asymptotische Notationen in Gleichungen

$$-2n^2+3n+1=2n^2+\Theta(n)$$

– $\Theta(n)$ fungiert hier als Platzhalter für eine beliebige Funktion f(n) aus $\Theta(n)$

- z.B.:
$$f(n) = 3n + 1$$

• o-Notation

- o-Notation stellt eine echte obere Schranke dar
- Ausschlaggebend ist, dass es für alle $c \in \mathbb{R}_{>0}$ gelten muss
- Außerdem < statt ≤</p>

- z.B.:
$$2n = o(n^2)$$
 und $2n^2 \neq o(n^2)$

$$o(g) = \{ f : \underbrace{\forall c \in \mathbb{R}_{>0}}, \exists n_0 \in \mathbb{N}, \forall n \ge n_0, 0 \le f(n) < cg(n) \}$$

Gilt für **alle** Konstanten c>0. In $\mathcal O ext{-Notation}$ gilt es für eine Konstante c>0

• ω -Notation

- ω -Notation stellt eine echte untere Schranke dar
- Ausschlaggebend ist, dass es für alle $c\in\mathbb{R}{>0}$ gelten muss
- Außerdem > statt ≥

- z.B.:
$$\frac{n^2}{2} = \omega(n)$$
 und $\frac{n^2}{2} \neq \omega(n^2)$

$$\omega(g) = \{ f : \forall c \in \mathbb{R}_{>0}, \exists n_0 \in \mathbb{N} \forall n \ge n_0, 0 \le cg(n) < f(n) \}$$

1.8 Insertion Sort (Sortieren durch Einfügen)

Idee

- Halte die linke Teilfolge sortiert
- Füge nächsten Schlüsselwert hinzu, indem es an die korrekte Position eingefügt wird
- Wiederhole den Vorgang bis Teilfolge aus der gesamten Liste besteht

Code

```
Insertion-Sort(A)

1  FOR j = 1 TO A.length - 1
2  key = A[j]
3  // Füge A[j] in die sortierte Sequenz A[0...j-1] ein
4  i = j - 1
5  WHILE i >= 0 and A[i] > key
6   A[i + 1] = A[i]
7  i = i - 1
8  A[i + 1] = key
```

Schleifeninvariante von Insertion Sort

- Zu Beginn jeder Iteration der for-Schleife besteht die Teilfolge A[0...j-1] aus den Elementen der ursprünglichen Teilfolge A[0...j-1] enthaltenen Elementen, allerdings in sortierter Reihenfolge.

Korrektheit von Insertion Sort

- Initialisierung:
 - * Beginn mit j=1, also Teilfeld A[0...j-1] besteht nur aus einem Element A[0]. Dies ist auch das ursprüngliche Element und Teilfeld ist sortiert.
- Fortsetzung:
 - * Zu zeigen ist, dass die Invariante bei jeder Iteration erhalten bleibt. Ausführungsblock der for-Schleife sorgt dafür, dass A[j-1], A[j-2],... je um Stelle nach rechts geschoben werden bis A[j] korrekt eingefügt wurde. Teilfeld A[0...j] besteht aus ursprünglichen Elementen und ist sortiert. Inkrementieren von j erhält die Invariante.
- Terminierung:
 - * Abbruchbedingung der for-Schleife, wenn j > A.length 1. Jede Iteration erhöht j. Dann bei Abbruch ist j = n und einsetzen in Invariante liefert das Teilfeld A[0...n-1] welches aus den ursprünglichen Elementen besteht und sortiert ist. Teilfeld ist gesamtes Feld.
- Algorithmus Insertion Sort arbeitet damit korrekt.

• Laufzeitanalyse von Insertion Sort

Zeile	Kosten	Anzahl
1	c_1	n
2 3 4	$_{0}^{c_{2}}$	n-1
3		n-1
4	c_4	n-1
5	c_5	$\sum_{j=1}^{n-1} t_j$
6	c_6	$\sum_{j=1}^{n-1} (t_j - 1)$
7	c_7	$\sum_{j=1}^{n-1} (t_j - 1)$
8	c_8	n-1
•	()	. /

- * Festlegung der Laufzeit für jede Zeile
- * Jede Zeile besitzt gewissen Kosten c_i
- * Jede Zeile wird x mal durchgeführt
- * Laufzeit = Anzahl * Kosten jeder Zeile
- * Schleifen: Abbruchüberprüfung zählt auch
- * t_i : Anzahl der Abfragen der While-Schleife

Laufzeit:
$$T(n) = c_1 n + c_2 (n-1) + c_4 (n-1) + c_5 \sum_{j=1}^{n-1} t_j + c_6 \sum_{j=1}^{n-1} (t_j - 1) + c_7 \sum_{j=1}^{n-1} (t_j - 1) + c_8 (n-1)$$

- Warum n in Zeile 1?
 - * Die Überprüfung der Fortführungsbedingung beinhaltet auch die letze Überprüfung
 - * Quasi die Überprüfung, durch die die Schleife abbricht
- Warum $\sum_{i=1}^{n-1}$ in Zeile 5?
 - * Aufsummierung aller einzelnen t_i über die Anzahl der Schleifendurchläufe
 - * Diese ist allerdings n-1 und nicht n, da die Abbruchüberprüfung dort auch enthalten ist
- Warum $t_j 1$ in Zeile 6?
 - * Selbes Argument wie oben, bei t_i ist die Abbruchüberprüfung enthalten
 - * Deswegen wird die while-Schleife nur $t_i 1$ -mal ausgeführt
- Best Case
 - * zu sortierendes Feld ist bereits sortiert
 - * t_i wird dadurch zu 1, da die While-Schleife immer nur einmal prüft (Abbruch)
 - * Die zwei Zeilen innerhalb der While-Schleife werden nie ausgeführt
 - * Durch Umformen ergibt sich, dass die Laufzeit eine lineare Funktion in n ist
- Worst Case
 - * zu sortierendes Feld ist umgekehrt sortiert
 - * t_j wird dadurch zu j+1, da die While-Schleife immer die gesamte Länge prüft
 - * Durch Umformen ergibt sich, dass die Laufzeit eine quadratische Funktion in n ist (n^2)
- Average Case
 - * im Mittel gut gemischt
 - * t_i wird dadurch zu j/2
 - * Die Laufzeit bleibt aber eine quadratische Funktion in n (n^2)
- Asymptotische Laufzeitbetrachtung Θ
 - T(n) lässt sich als quadratische Funktion $an^2 + bn + c$ betrachten
 - Terme niedriger Ordnung sind für große n irrelevant
 - Deswegen Vereinfachung zu n^2 und damit $\Theta(n^2)$

1.9 Bubble Sort

Idee

- Vergleiche Paare von benachbarten Schlüsselwerten
- Tausche das Paar, falls rechter Schlüsselwert kleiner als linker

Code

• Analyse von Bubble Sort

- Anzahl der Vergleiche:
 - * Es werden stets alle Elemente der Teilfolge miteinander verglichen
 - * Unabhängig von der Vorsortierung sind Worst und Best Case identisch
- Anzahl der Vertauschungen:
 - * Best Case: 0 Vertauschungen
 - * Worst Case: $\frac{n^2-n}{2}$ Vertauschungen
- Komplexität:
 - * Best Case: $\Theta(n)$
 - * Average Case: $\Theta(n^2)$
 - * Worst Case: $\Theta(n^2)$

1.10 Selection Sort

- Idee
 - Sortieren durch direktes Auswählen
 - MinSort: "wähle kleines Element in Array und tausche es nach vorne"
 - MaxSort: "wähle größtes Element in Array und tausche es nach vorne"
- · Code MinSort

1.11 Divide-And-Conquer Prinzip

- Anderer Ansatz im Gegensatz zu z.B. InsertionSort (inkrementelle Herangehensweise)
- Laufzeit ist im schlechtesten Fall immer noch besser als InsertionSort
- Prinzip: Zerlege das Problem und löse es direkt oder zerlege es weiter
- Divide:
 - Teile das Problem in mehrere Teilprobleme auf
 - Teilprobleme sind Instanzen des gleichen Problems
- Conquer:
 - Beherrsche die Teilprobleme rekursiv
 - Falls Teilprobleme klein genug, löse sie auf direktem Weg
- Combine:
 - Vereine die Lösungen der Teilprobleme zu Lösung des ursprünglichen Problems

1.12 Merge Sort

• Idee

- Divide: Teile die Folge aus n Elementen in zwei Teilfolgen von je $\frac{n}{2}$ Elemente auf
- Conquer: Sortiere die zwei Teilfolgen rekursiv mithilfe von MergeSort
- Combine: Vereinige die zwei sortierten Teilfolgen, um die sortierte Lösung zu erzeugen

Code

```
MERGE-SORT(A,p,r)

1  IF p < r
2    q = [(p+r)/2] // Teilen in 2 Teilfolgen
3    MERGE-SORT(A,p,q) // Sortieren der beiden Teilfolgen
4    MERGE-SORT(A,q+1,r)
5    MERGE(A,p,q,r) // Vereinigung der beiden sortierten Teilfolgen</pre>
```

```
MERGE(A,p,q,r)
  n_1 = q - p + 1
  Let L[\emptyset \dots n_1] and R[\emptyset \dots n_2] be new arrays
  FOR i = 0 TO n_1 - 1 // Auffüllen der neu erstellten Arrays
    L[i] = A[p + i]
  FOR j = 0 TO n_2 - 1
     R[j] = A[q + j + 1]
  \mathsf{L}[n_1] = \infty // Einfügen des Sentinel-Wertes
  R[n_2] = \infty
  i = 0
10
  j = 0
11
  FOR k = p TO r // Eintragweiser Vergleich der Elemente
     IF L[i] \leq R[j]
         A[k] = L[i] // Sortiertes Zurückschreiben in Original-Array
14
         i = i + 1
15
     ELSE
16
         A[k] = R[j]
17
          j = j + 1
```

· Korrektheit von MergeSort

- Schleifeninvariante

Zu Beginn jeder Iteration der for-Schleife (Letztes for in Methode MERGE) enthält das Teilfeld A[p...k-1] die k-p kleinsten Elemente aus L[0... n_1] und R[0... n_2] in sortierter Reihenfolge. Weiter sind L[i] und R[i] die kleinsten Elemente ihrer Arrays, die noch nicht zurück kopiert wurden.

- Initialisierung

Vor der ersten Iteration gilt k=p. Daher ist A[p...k-1] leer und enthält 0 kleinste Elemente von L und R. Wegen i=j=0 sind L[i] und R[i] die kleinsten Elemente ihrer Arrays, die noch nicht zurück kopiert wurden.

- Fortsetzung

Müssen zeigen, dass Schleifeninvariante erhalten bleibt. Dafür nehmen wir an, dass $L[i] \leq R[j]$. Dann ist L[i] kleinstes Element, welches noch nicht zurück kopiert wurde. Da Array A[p...k-1] die k-p kleinsten Elemente enthält, wird der Array A[p...k] die k-p+1 kleinsten Elemente enthalten, nachdem der Wert nach der Durchführung von A[k]=L[i] kopiert wurde. Die Erhöhung der Variablen k und i stellt die Schleifeninvariante für die nächste Iteration wieder her. Wenn L[i]>R[j] dann analoges Argument in der ELSE-Anweisung.

- Terminierung

Beim Abbruch gilt k=r+1. Durch die Schleifeninvariante enthält A[p...r] die kleinste Elemente von $L[0...n_1]$ und $R[0...n_2]$ in sortierter Reihenfolge. Alle Elemente außer der Sentinels wurden komplett zurück kopiert. MergeSort ist außerdem ein stabiler Algorithmus.

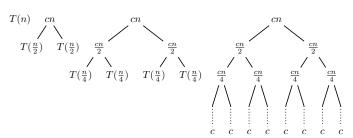
· Analyse von MergeSort

- Ziel: Bestimme Rekursionsgleichung für Laufzeit T(n) von n Zahlen im schlechtesten Fall
- Divide: Berechnung der Mitte des Feldes: Konstante Zeit $\Theta(1)$
- Conquer: Rekursives Lösen von zwei Teilproblemen der Größe $\frac{n}{2}$: Laufzeit von 2 $T(\frac{n}{2})$
- Combine: MERGE auf einem Teilfeld der Länge n: Lineare Zeit $\Theta(n)$

$$T(n) = \begin{cases} \Theta(1) & \text{falls } n = 1 \\ 2 \ T(\frac{n}{2}) + \Theta(n) & \text{falls } n > 1 \end{cases}$$

- Lösen der Rekursionsgleichung mithilfe eines Rekursionsbaums

$$T(n) = \begin{cases} c & \text{falls } n = 1, \\ 2T(\frac{n}{2}) + cn & \text{falls } n > 1 \end{cases}$$



- * Verwenden der Konstante c statt $\Theta(1)$
- st cn stellt den Aufwand an der ersten Ebene dar
- * Der addierte Aufwand jeder Stufe (aller Knoten) ist auch cn
- * Die Azahl der Ebenen lässt sich mithilfe von lg(n) + 1 bestimmen (2-er Logarithmus)
- * Damit ergibt sich für die Laufzeit: $cn \cdot lg(n) + cn$
- * Für $\lim_{n\to\infty}$ wird diese zu $n \cdot lg(n)$
- * Laufzeit beträgt damit $\Theta(n \cdot lg(n))$
- * Laufzeit von MergeSort ist in jedem Fall gleich

1.13 Quicksort

• Idee

- Pivotelement:

Wahl eines Pivotelement x aus dem Array

- Divide:

Zerlege den Array A[p...r] in zwei Teilarrays A[p...q-1] und A[q+1...r], sodass jedes Element von A[p...q-1] kleiner oder gleich A[q] ist, welches wiederum kleiner oder gleich jedem Element von A[q+1...r] ist. Berechnen Sie den Index q als Teil vom Partition Algorithmus.

- Conquer:

Sortieren beider Teilarrays A[p...q-1] und A[q+1...r] durch rekursiven Aufruf von Quicksort.

Combine.

Da die Teilarrays bereits sortiert sind, ist keine weitere Arbeit nötig um diese zu vereinigen. A[p...r] ist nun sortiert.

Code

```
QUICKSORT(A,p,r)

IF p < r // Überprüfung, ob Teilarray leer ist

q = PARTITION(A,p,r)

QUICKSORT(A,p,q-1)

QUICKSORT(A,q+1,r)
```

· Korrektheit von Quicksort

- Schleifeninvariante:

Zu Beginn jeder Iteration der for-Schleife gilt für den Arrayindex k folgendes:

- (a) Ist $p \le k \le i$, so gilt A[k] $\le x$
- (b) Ist $i + 1 \le k \le j 1$, so gilt A[k] > x
- (c) Ist k = r, so gilt A[k] = x
- Initialisierung:

Vor der ersten Iteration gilt i=p-1 und j=p. Da es keine Werte zwischen p und j gibt und es auch keine Werte zwischen i+1 und j-1 gibt, sind die ersten beiden Eigenschaften trivial erfüllt. Die Zuweisung in x=A[r] sorgt für die Erfüllung der dritten Eigenschaft.

- Fortsetzung:

Zwei mögliche Fälle durch IF A[j] $\leq x$. Wenn A[j] > x, dann inkrementiert die Schleife nur den Index j. Dann gilt Bedingung 2 für A[j-1] und alle anderen Einträge bleiben unverändert. Wenn A[j] $\leq x$, dann wird Index i inkrementiert und die Einträge A[i] und A[j] getauscht und schließlich der Index j erhöht. Wegen des Vertauschens gilt A[i] $\leq x$ und Bedingung 1 ist erfüllt. Analog gilt A[j-1] > x, da das Element welches mit A[j-1] vertauscht wurde wegen der Invariante gerade größer als x ist.

- Terminierung:

Bei der Terminierung gilt, dass j=r. Daher gilt, dass jeder Eintrag des Arrays zu einer der drei durch die Invariante beschriebenen Mengen gehört.

· Performanz von Quicksort

- Abhängig von der **Balanciertheit** der Teilarrays
 - * Definition Balanciert: ungefähr gleiche Anzahl an Elementen
 - * Teilarrays balanciert: Laufzeit asymptotisch so schnell wie MergeSort
 - * Teilarrays unbalanciert: Laufzeit kann so langsam wie InsertionSort laufen
- Zerlegung im schlechtesten Fall
 - * Partition zerlegt Problem in ein Teilproblem mit n-1 Elementen und eins mit 0 Elementen
 - * Unbalancierte Zerlegung mit Kosten $\Theta(n)$ zieht sich durch gesamte Rekursion
 - * Aufruf auf Feld der Größe 0: $T() = \Theta(1)$
 - * Laufzeit (rekursiv):
 - $T(n) = T(n-1) + T(0) + \Theta(n) = T(n-1) + \Theta(n)$
 - · Insgesamt folgt: $T(n) = \Theta(n^2)$
- Zerlegung im besten Fall
 - * Problem wird so balanciert wie möglich zerlegt
 - * Zwei Teilprobleme mit maximaler Größe von $\frac{n}{2}$
 - * Zerlegung kostet $\Theta(n)$
 - * Laufzeit (rekursiv):
 - $T(n) \le 2T(\frac{n}{2}) + \Theta(n)$
 - · Laufzeit beträgt: O(n lg(n))
 - * Solange die Aufteilung konstant bleibt, bleibt die Laufzeit $O(n \lg(n))$

1.14 Laufzeitanalyse von rekursiven Algorithmen

• Analyse von Divide-And-Conquer Algorithmen

- -T(n) ist Laufzeit eines Problems der Größe n
- Für kleines Problem benötigt die direkte Lösung eine konstante Zeit $\Theta(1)$
- Für sonstige n gilt:
 - $\ast\,$ Aufteilen eines Problems führt zu a Teilproblemen
 - * Jedes dieser Teilprobleme hat die Größe $\frac{1}{h}$ der Größe des ursprünglichen Problems
 - * Lösen eines Teilproblems der Größe $\frac{n}{b}$: $T(\frac{n}{b})$
 - * Lösen a solcher Probleme: $a T(\frac{n}{h})$
 - * D(n): Zeit um das Problem aufzuteilen (Divide)
 - * C(n): Zeit um Teillösungen zur Gesamtlösung zusammenzufügen (Combine)

$$T(n) = \begin{cases} \Theta(1) & \text{falls } n \le c \\ a \ T(\frac{n}{b}) + D(n) + C(n) & \text{sonst} \end{cases}$$

· Subsitutionsmethode

- Idee: Erraten einer Schranke und Nutzen von Induktion zum Beweis der Korrektheit
- Ablauf:
 - (a) Rate die Form der Lösung (Scharfes Hinsehen oder kurze Eingaben ausprobieren/einsetzen)
 - (b) Anwendung von vollständiger Induktion zum Finden der Konstanten und Beweis der Lösung

- Beispiel

- * Betrachten von MergeSort:
 - $T(1) \leq c$

$$T(n) \leq T(\left|\frac{n}{2}\right|) + T(\left[\frac{n}{2}\right]) + cn$$

* Ziel:

Obere Abschätzung $T(n) \leq g(n)$ mit g(n) ist eine Funktion, die durch eine geschlossene Formel dargestellt werden kann.

Wir "raten": $T(n) \le 4cn \ lg(n)$ und nehmen dies für alle n' < n an und zeigen es für n.

- * Induktion:
 - · lg steht hier für log_2
 - · n = 1: $T(1) \le c$

$$n = 2$$
: $T(2) \le T(1) + T(1) + 2c$
 $\le 4c \le 8c$
 $T(2) = 4c * 2 lg(2) = 8c$

- * Hilfsbehauptungen:
 - $\cdot (1): \left| \frac{n}{2} \right| + \left[\frac{n}{2} \right] = n$
 - (2): $\left| \frac{n}{2} \right| \le \frac{n}{2} \le \frac{2}{3}n$
 - (3): $log_c(\frac{a}{b}) = log_c(a) log_c(b)$
 - (4): $log_c(a * b) = log_c(a) + log_c(b)$
- * Induktionsschritt:
 - · Annahme: n > 2 und sei Behauptung wahr für alle n' < n.

$$\begin{split} \mathsf{T}(\mathsf{n}) & \leq T(\left\lfloor \frac{n}{2} \right\rfloor) + T(\left\lceil \frac{n}{2} \right\rceil) + cn \\ & \leq 4c \left\lfloor \frac{n}{2} \right\rfloor \ lg(\left\lfloor \frac{n}{2} \right\rfloor) + 4c \left\lceil \frac{n}{2} \right\rceil \ lg(\left\lceil \frac{n}{2} \right\rceil) + cn \\ (\mathsf{HB}) & \leq 4c \cdot lg(\frac{2}{3}n) \cdot \left(\left\lfloor \frac{n}{2} \right\rfloor + \left\lceil \frac{n}{2} \right\rceil + cn \\ & \leq 4c \cdot lg(\frac{2}{3}n) \cdot n + cn \\ (\mathsf{HB}) & \leq 4cn \cdot \left(lg(\frac{2}{3}) + lg(n)\right) + cn \\ & = 4cn \cdot lg(n) + 4cn \cdot lg(\frac{2}{3}) \\ & = 4cn \cdot lg(n) + cn(1 + 4 \cdot (lg(2) - lg(3))) \\ & \leq 4cn \cdot lg(n) \\ & \Rightarrow \Theta(n \ lg(n)) \end{split}$$

Rekursionsbaum

- Idee: Stellen das Ineinander-Einsetzen als Baum dar und Analyse der Kosten
- Ablauf:
 - (a) Jeder Knoten stellt die Kosten eines Teilproblems dar
 - * Die Wurzel stellt die zu analysierenden Kosten T(n) dar
 - * Die Blätter stellen die Kosten der Basisfälle dar (z.B. T(0))
 - (b) Berechnen der Kosten innerhalb jeder Ebene des Baums
 - (c) Die Gesamtkosten sind die Summe über die Kosten aller Ebenen
- Rekursionsbaum ist nützlich um Lösung für Subsitutionsmethode zu erraten

- Beispiel: $T(n) = 3T(\lfloor \frac{n}{4} \rfloor) + \Theta(n^2)$
 - * Vorüberlegungen:

$$\Rightarrow T(n) = 3T(\frac{n}{4}) + cn^2 \ (c > 0)$$

- · Je Abstieg verringert sich die Größe des Problems um den Faktor 4.
- · Erreichen der Randbedingung ist vonnöten, die Frage ist wann dies geschieht.
- · Größe Teilproblem bei Level i: $\frac{n}{4^i}$
- · Erreichen Teilproblem der Größe 1, wenn $\frac{n}{4^i}=1$, d.h. wenn $i=log_4(n)$ \Rightarrow Baum hat also log_4n+1 Ebenen
- * Kosten pro Ebene:
 - · Jede Ebene hat 3-mal soviele Knoten wie darüber liegende
 - · Anzahl der Knoten in Tiefe i ist 3^i
 - · Kosten $c(\frac{n}{4^i})^2$, $i=0...log_4n-1$
 - · Anzahl · Kosten = $3^i \cdot c(\frac{n}{4^i})^2 = (\frac{3}{16})^i \cdot cn^2$
- * Unterste Ebene:
 - $\cdot \ 3^{log_4(n)} = nlog_4(3)$ Knoten
 - · Jeder Knoten trägt T(1) Kosten bei
 - · Kosten unten: $n^{log_4(3)} \cdot T(1) = \Theta(n^{log_4(3)})$
- * Addiere alle Kosten aller Ebenen:

$$\begin{split} \cdot \ T(n) &= cn^2 + \tfrac{3}{16}cn^2 + (\tfrac{3}{16})^2cn^2 + ... + (\tfrac{3}{16})^{log_4n-1}cn^2 + \Theta(n^{log_4(3)}) \\ &= \sum_{i=0}^{log_4n-1} (\tfrac{3}{16})^icn^2 + \Theta(n^{log_4^3}) \\ &= \tfrac{(\tfrac{3}{16}^{log_4n})-1}{\tfrac{3}{20}-1} \cdot cn^2 + \Theta(n^{log_43}) \text{ (Verwendung der geometrischen Reihe)} \end{split}$$

· Verwendung einer unendlichen fallenden geometrischen Reihe als obere Schranke:

$$\begin{split} T(n) &= \sum_{i=0}^{log_4n-1} (\frac{3}{16})^i \cdot cn^2 + \Theta(n^{log_43}) \\ &< \sum_{i=0}^{\infty} (\frac{3}{16})^i \cdot cn^2 + \Theta(n^{log_43}) \\ &= \frac{1}{1-\frac{3}{16}} \cdot cn^2 + \Theta(n^{log_43}) \\ &= \frac{16}{13} \cdot cn^2 + Theta(n^{log_43}) = O(n^2) \end{split}$$

- * Jetzt Subsitutionsmethode:
 - · Zu zeigen: $\exists d > 0 : T(n) < dn^2$
 - · Induktionsanfang:

$$T(n) = 3 \cdot T(\lfloor \frac{1}{4} \rfloor) + c \cdot 1^{2}$$
$$= 3 \cdot T(0) + c = c$$

· Induktionsschritt:

$$\begin{split} T(n) &\leq 3 \cdot T(\left\lfloor \frac{n}{4} \right\rfloor) + cn^2 \\ &\leq 3 \cdot d(\left\lfloor \frac{n}{4} \right\rfloor)^2 + cn^2 \\ &\leq 3d(\frac{n}{4})^2 + cn^2 \\ &= \frac{3}{16}dn^2 + cn^2 \\ &\leq dn^2 \text{, falls } d \geq \frac{16}{13}c \end{split}$$

Mastertheorem

- Idee:

Seien $a \geq 1$ und b > 1 Konstanten. Sei f(n) eine positive Funktion und T(n) über den nichtnegativen ganzen Zahlen über die Rekursionsgleichung $T(n) = a \ T(\frac{n}{b}) + f(n)$ defininiert, wobei wir $\frac{n}{b}$ so interpretieren, dass damit entweder $\left\lfloor \frac{n}{b} \right\rfloor$ oder $\left\lceil \frac{n}{b} \right\rceil$ gemeint ist. Dann besitzt T(n) die folgenden asymptotischen Schranken (a und b werden aus f(n) gelesen):

- (a) Gilt $f(n) = O(n^{\log_b(a-\epsilon)})$ für eine Konstante $\epsilon > 0$, dann $T(n) = \Theta(n^{\log_b(a)})$
- (b) Gilt $f(n) = \Theta(n^{log_b(a)})$, dann gilt $T(n) = \Theta(n^{log_b(a)}lg(n))$
- (c) Gilt $f(n) = \Omega(n^{\log_b(a+\epsilon)})$ für eine Konstante $\epsilon > 0$ und a $f(\frac{n}{b}) \le c$ f(n) für eine Konstante c < 1 und hinreichend großen n, dann ist $T(n) = \Theta(f(n))$

- Erklärung:

- * In jedem der 3 Fälle wird die Funktion f(n) mit $n^{log_b(a)}$ verglichen
 - (a) Wenn f(n) polynomial kleiner ist als $n^{log_b(a)}$, dann $T(n) = \Theta(n^{log_b(a)})$
 - (b) Wenn f(n) und $n^{log_b(a)}$ die gleiche Größe haben, gilt $T(n) = \Theta(n^{log_b(a)}lg(n))$
 - (c) Wenn f(n) polynomial größer als $n^{\log_b(a)}$ und a $f(\frac{n}{b}) \leq c$ f(n) erfüllt, dann $T(n) = \Theta(f(n))$
- * (polynomial größer/kleiner: um Faktor n^{ϵ} asymptotisch größer/kleiner)

- Nicht abgedeckte Fälle:

- * Wenn einer dieser Fälle eintritt, kann das Mastertheorem nicht angewendet werden
 - (a) Wenn f(n) kleiner ist als $n^{\log_b(a)}$, aber nicht polynomial kleiner
 - (b) Wenn f(n) größer ist als $n^{log_b(a)}$, aber nicht polynomial größer
 - (c) Regularitätsbedingung $a f(\frac{n}{h}) \le c f(n)$ wird nicht erfüllt
 - (d) a oder b sind nicht konstant (z.B. $a = 2^n$)

- Beispiel:

*
$$T(n) = 9T(\frac{n}{3}) + n$$

• $a = 9, b = 3, f(n) = n$
• $log_b(a) = log_3(9) = 2$
• $f(n) = n = O(n^{log_b(a-\epsilon)})$
= $O(n^{2-\epsilon})$

· Ist diese Gleichung für ein $\epsilon>0$ erfüllt? $\Rightarrow \epsilon=1$

• 1. Fall
$$\Rightarrow T(n) = \Theta(n^2)$$

*
$$T(n) = T(\frac{2n}{3}) + 1$$

$$a = 1, b = \frac{3}{2}, f(n) = 1$$

$$\cdot \log_{\frac{3}{2}} 1 = 0$$

$$f(n) = 1 = O(n^{log_b(a)})$$
$$= O(n^0)$$
$$= O(1)$$

· 2.Fall
$$\Rightarrow T(n) = \Theta(1 * lg(n)) = \Theta(lg(n))$$

*
$$T(n) = 3(T^{\frac{n}{4}}) + n lg(n)$$

·
$$a = 3, b = 4, f(n) = n \lg(n)$$

$$n^{\log_b(a)} = n^{\log_4(3)} < n^{0.793}$$

· $\epsilon = 0.1$ im Folgenden

$$f(n) = n \ lg(n) \ge n \ge n^{0.793 + 0.1} \ge n^{0.793}$$

· 3.Fall
$$\Rightarrow f(n) = \Omega(n^{log_b(a+0.1)})$$

$$\cdot af(\frac{n}{b}) = 3f(\frac{n}{4}) = 3(\frac{n}{4}) lg(\frac{n}{4}) \le \frac{3}{4}n lg(n)$$

· Damit ist auch die Randbedingung erfüllt und $T(n) = \Theta(n \ lg(n))$

Grundlegende Datenstrukturen	Fortgeschrittene Datenstrukturen	Randomisierte Datenstrukturen
Stacks	Rot-Schwarz-Bäume	Skip Lists
Verkettete Listen	AVL-Bäume	Hash Tables
Queues	Splay-Bäume	Bloom-Filter
Bäume	Heaps	
Binäre Suchbäume	B-Bäume	

Tabelle 1: Übersicht Datenstrukturen