

# 1 Sortieren

## 1.1 Einführung - Das Sortierproblem

### Definition — Das Sortierproblem

Ausgangspunkt:

$$\boxed{D_1} \boxed{D_2} \cdots \boxed{D_n}$$

ABBILDUNG 1: Folge von Datensätzen  $D_1, D_2, \dots, D_n$

**Ziel:** Datensätze so anzuordnen, dass die Schlüsselwerte sukzessive ansteigen (oder absteigen)

**Bedingung:** Schlüssel(werte) müssen vergleichbar sein

- zu sortierende Elemente heißen auch Schlüssel(werte)

### Durchführung

- **Eingabe:** Sequenz von Schlüsselwerten  $\{a_1, a_2, \dots, a_n\}$
- Eingabe ist eine **Instanz** des Sortierproblems
- **Ausgabe:** Permutation  $\{a'_1, a'_2, \dots, a'_n\}$  derselben Folge mit Eigenschaft  $a'_1 \leq \dots \leq a'_n$
- Algorithmus ist **korrekt**, wenn dieser das Problem für alle Instanzen löst

## 1.2 Arrays

### Definition — Array Reihung (Feld) fester Länge von Daten des gleichen Typs

	0	1	2	3	4	5	6	7	8
A	12	47	17	98	72				

ABBILDUNG 2: beispielhafte Darstellung eines Arrays

A Bezeichnung des Arrays mit dem Namen „A“

$A[i]$  Zugriff auf das  $(i + 1)$ -te Element des Arrays

### Beispiel:

$$A[2] = 17$$

⇒ Arrays erlauben effizienten Zugriff auf Elemente: konstanter Aufwand

### 1.3 Exkurs: Totale Ordnung

**Definition — Totale Ordnung** Sei  $M$  eine nicht leere Menge und  $\leq \subseteq M \times M$  eine binäre Relation auf  $M$ . Das Paar  $(M, \leq)$  heißt genau dann eine totale Relation auf der Menge  $M$ , wenn folgende Eigenschaften erfüllt sind:

- Reflexivität:  $\forall x \in M : x \leq x$
- Transitivität:  $\forall x, y, z \in M : x \leq y \wedge y \leq z \Rightarrow x \leq z$
- Antisymmetrie:  $\forall x, y \in M : x \leq y \wedge y \leq x \Rightarrow x = y$
- Totalität:  $\forall x, y \in M : x \leq y \vee y \leq x$

#### Beispiele

- $\leq$  Ordnung auf natürlichen Zahlen
- Lexikographische Ordnung  $\leq_{lex}$  ist eine totale Ordnung

### 1.4 Vergleichskriterien von Suchalgorithmen

Berechnungsaufwand	<ul style="list-style-type: none"><li>• <math>\mathcal{O}(n)</math></li></ul>
Effizienz	<ul style="list-style-type: none"><li>• Best Case vs. Average Case vs Worst Case</li></ul>
Speicherbedarf	<ul style="list-style-type: none"><li>• in-Place (in situ): zusätzlicher Speicher von der Eingabegröße unabhängig</li><li>• out-of-place: Speichermehrbedarf von Eingabegröße abhängig</li></ul>
Stabilität	<ul style="list-style-type: none"><li>• stabile Verfahren verändern die Reihenfolge von äquivalenten Elementen nicht</li></ul>
Anwendung als Auswahlfaktor	<ul style="list-style-type: none"><li>• Hauptoperationen beim Sortieren: Vergleichen und Vertauschen</li><li>• Anwendung spielt eine enorme Rolle:<ul style="list-style-type: none"><li>– Verfahren mit vielen Vertauschungen und wenig Vergleichen, wenn Vergleichen teuer</li><li>– Verfahren mit wenig Vertauschungen und vielen Vergleichen, wenn Umsortieren teuer</li></ul></li></ul>

---

## 1.5 Analyse von Algorithmen (I)

---

### Schleifeninvariante (SIV):

- Sonderform der Invariante
- Am Anfang/Ende jedes Schleifendurchlaufs und vor/nach jedem Schleifendurchlauf gültig
- Wird zur Feststellung der Korrektheit von Algorithmen verwendet
- Eigenschaften:
  - Initialisierung Invariante ist vor jeder Iteration wahr
  - Fortsetzung Wenn SIV vor der Schleife wahr ist, dann auch bis Beginn der nächsten Iteration
  - Terminierung SIV liefert bei Schleifenabbruch, helfende Eigenschaft für Korrektheit
- Beispiel für Umsetzung: **Insertion Sort - SIV**

### Laufzeitanalyse:

- Aufstellung der Kosten und Durchführungsanzahl für jede Zeile des Quelltextes
- Beachte: Bei Schleifen wird auch der Aufruf gezählt, der den Abbruch einleitet
- Beispiel für Umsetzung: **Insertion Sort - Laufzeit**
- Zusätzliche Überprüfung des Best Case, Worst Case und Average Case

### Effizienz von Algorithmen:

- |                   |  |
|-------------------|--|
| Effizienzfaktoren | <ul style="list-style-type: none"><li>• Rechenzeit (Anzahl der Einzelschritte)</li><li>• Kommunikationsaufwand</li><li>• Speicherplatzbedarf</li><li>• Zugriffe auf Speicher</li></ul> |
| Laufzeitfaktoren  | <ul style="list-style-type: none"><li>• Länge der Eingabe</li><li>• Implementierung der Basisoperationen</li><li>• Takt der CPU</li></ul>  |

---

## 1.6 Analyse von Algorithmen (II)

---

### Komplexität:

- Abstrakte Rechenzeit  $T(n)$  ist abhängig von den Eingabedaten
- Übliche Betrachtungsweise der Rechenzeit ist asymptotische Betrachtung

### Asymptotik:

- Annäherung an einer sich ins Unendliche verlaufende Kurve
- z.B.:  $f(x) = \frac{1}{x} + x$  | Asymptote:  $g(x) = x$  | ( $\frac{1}{x}$  läuft gegen Null)

### Asymptotische Komplexität:

- Abschätzung des zeitlichen Aufwands eines Algorithmus in Abhängigkeit einer Eingabe
- Beispiel für Umsetzung: **Insertion Sort - Laufzeit  $\Theta$**

### Asymptotische Notation:

- Betrachtung der Laufzeit  $T(n)$  für sehr große Eingaben  $n \in \mathbb{N}$
- Komplexität ist unabhängig von konstanten Faktoren und Summanden
- Nicht berücksichtigt: Rechnergeschwindigkeit / Initialisierungsaufwände
- Komplexitätsmessung via Funktionsklasse ausreichend
  - Verhalten des Algorithmus für große Problemgrößen
  - Veränderung der Laufzeit bei Verdopplung der Problemgröße

### Gründe für die Nutzung der theoretischen Betrachtung statt der Messung der Laufzeit

- |                  |   |
|------------------|---|
| Vergleichbarkeit | <ul style="list-style-type: none"><li>• Laufzeit abhängig von konkreter Implementierung und System</li><li>• Theoretische Betrachtung ist frei von Abhängigkeiten und Seiteneffekten</li><li>• Theoretische Betrachtung lässt direkte Vergleichbarkeit zu</li></ul> |
|------------------|---|

- |         |  |
|---------|--|
| Aufwand | <ul style="list-style-type: none"><li>• Wieviele Testreihen?</li><li>• In welcher Umgebung?</li><li>• Messen führt in der Ausführung zu hohem, praktischen Aufwand</li></ul> |
|---------|--|

- |                      |  |
|----------------------|--|
| Komplexitätsfunktion | <ul style="list-style-type: none"><li>• Wachstumsverhalten ausreichend</li><li>• Praktische Evaluation mit Zeiten nur für Auswahl von Systemen möglich</li><li>• Theoretischer Vergleich (Funktionsklassen) hat ähnlichen Erkenntnisgewinn</li></ul> |
|----------------------|--|

## 1.7 Analyse von Algorithmen (III)

### Übersicht

$$\Theta =$$

$$\mathcal{O} \leq$$

$$\Omega \geq$$

### $\Theta$ -Notation

- $\Theta$ -Notation beschränkt eine Funktion asymptotisch von oben und unten
- Funktionen  $f, g : \mathbb{N} \rightarrow \mathbb{R}_{>0}$  ( $\mathbb{N}$ : Eingabelänge,  $\mathbb{R}$ : Zeit)

$$\Theta(g) = \{f : \exists c_1, c_2 \in \mathbb{R}_{>0}, n_0 \in \mathbb{N}, \forall n \geq n_0, 0 \leq c_1 g(n) \leq f(n) \leq c_2 g(n)\}$$





ABBILDUNG 3: Veranschaulichung  $\Theta$ -Notation

- $\Theta(g)$  enthält alle  $f$ , die genauso schnell wachsen wie  $g$
- **Schreibweise:**  $f \in \Theta(g)$  (korrekt), manchmal auch  $f = \Theta(g)$
- $g(n)$  ist eine asymptotisch scharfe Schranke von  $f(n)$
- $f(n) = \Theta(g(n))$  gilt, wenn  $f(n) = \mathcal{O}(g(n))$  und  $f(n) = \Omega(g(n))$  erfüllt sind
- z.B.:  $f(n) = \frac{1}{2}n^2 - 3n \mid f(n) \in \Theta(n^2)$ ?
- Aus  $\Theta(n^2)$  folgt, dass  $g(n) = n^2$
- **Vorgehen:**
  - Finden eines  $n_0$  und  $c_1, c_2$ , sodass
  - $c_1 * g(n) \leq f(n) \leq c_2 * g(n)$  erfüllt ist
  - Konkret:  $c_1 * n^2 \leq \frac{1}{2}n^2 - 3n \leq c_2 * n^2$
  - Division durch  $n^2$ :  $c_1 \leq \frac{1}{2} - \frac{3}{n} \leq c_2$
  - Ab  $n = 7$  positives Ergebnis:  $0,0714 \mid n_0 = 7$
  - Deswegen setzen wir  $c_1 = \frac{1}{14}$
  - Für  $n \rightarrow \infty$ :  $0,5 \mid c_2 = 0,5$
  - Natürlich auch andere Konstanten möglich

## O-Notation

- O-Notation beschränkt eine Funktion asymptotisch von oben

$$O(g) = \{f : \exists c \in \mathbb{R}_{>0}, n_0 \in \mathbb{N}, \forall n \geq n_0, 0 \leq f(n) \leq cg(n)\}$$





ABBILDUNG 4: Veranschaulichung O-Notation

- $O(g)$  enthält alle  $f$ , die höchstens so schnell wie  $g$  wachsen
- **Schreibweise:**  $f = O(g)$
- $f(n) = \Theta(g) \rightarrow f(n) = O(g) \mid \Theta(g(n)) \subseteq O(g(n))$
- Ist  $f$  in der Menge  $\Theta(g)$ , dann auch in der Menge  $O(g)$
- z.B.:  $f(n) = n + 2 \mid f(n) = O(n)$ ?
- Ja  $f(n)$  ist Teil von  $O(n)$  für z.B.  $c = 2$  und  $n_0 = 2$

## O-Notation Rechenregeln

- Konstanten**
- $f(n) = a$  mit  $a \in \mathbb{R}$  konstante Funktion  $\rightarrow f(n) = O(1)$
  - z.B.  $3 \in O(1)$

- Skalare Multiplikation**
- $f = O(g)$  und  $a \in \mathbb{R} \rightarrow a * f = O(g)$

- Addition**
- $f_1 = O(g_1)$  und  $f_2 = O(g_2) \rightarrow f_1 + f_2 = O(\max\{g_1, g_2\})$

- Multiplikation**
- $f_1 = O(g_1)$  und  $f_2 = O(g_2) \rightarrow f_1 * f_2 = O(g_1 * g_2)$

## Ω-Notation

- Ω-Notation beschränkt eine Funktion asymptotisch von unten

$$\Omega(g) = \{f : \exists c \in \mathbb{R}_{>0}, n_0 \in \mathbb{N}, \forall n \geq n_0, 0 \leq cg(n) \leq f(n)\}$$





ABBILDUNG 5: Veranschaulichung

- Ω-Notation enthält alle  $f$ , die mindestens so schnell wie  $g$  wachsen
- **Schreibweise:**  $f = \Omega(g)$

## Komplexitätsklassen

Klasse	Bezeichnung	Beispiel
$\Theta(1)$	Konstant	Einzeloperation
$\Theta(\log n)$	Logarithmisch	Binäre Suche
$\Theta(n)$	Linear	Sequentielle Suche
$\Theta(n \log n)$	Quasilinear	Sortieren eines Arrays
$\Theta(n^2)$	Quadratisch	Matrixaddition
$\Theta(n^3)$	Kubisch	Matrixmultiplikation
$\Theta(n^k)$	Polynomiell	
$\Theta(2^n)$	Exponentiell	Travelling-Salesman*
$\Theta(n!)$	Faktoriell	Permutationen

TABELLE 1: Komplexitätsklassen ( $n$ = Länge der Eingabe)

Eingabegröße $n$	$\log_{10} n$	$n$	$n^2$	$n^3$	$2^n$
10	$1\mu s$	$10\mu s$	$100\mu s$	1ms	$\sim 1 \text{ ms}$
100	$2\mu s$	$100\mu s$	10ms	1s	$\sim 4 \times 10^{16} \text{ y}$
1000	$3\mu s$	1ms	1s	16min 40s	?
10000	$4\mu s$	10ms	1min 40s	$\sim 11,5 \text{ d}$	?
100000	$5\mu s$	100ms	2h 64min 40s	$\sim 31,7 \text{ y}$	?

TABELLE 2: Komplexitätsklassen-Ausführungsdauer, falls eine Operation  $n$  genau  $1\mu s$  dauert

Es gilt:  $\log(n) < \sqrt{n} < n < n \cdot \log(n) < n^2 < n! < 2^n < n^n$

## Asymptotische Notationen in Gleichungen

- $2n^2 + 3n + 1 = 2n^2 + \Theta(n)$
- $\Theta(n)$  fungiert hier als Platzhalter für eine beliebige Funktion  $f(n)$  aus  $\Theta(n)$
- z.B.:  $f(n) = 3n + 1$

## $o$ -Notation

- $o$ -Notation stellt eine echte obere Schranke dar
- Ausschlaggebend ist, dass es für alle  $c \in \mathbb{R}_{>0}$  gelten muss
- Außerdem  $<$  statt  $\leq$
- z.B.:  $2n = o(n^2)$  und  $2n^2 \neq o(n^2)$

$$o(g) = \{f : \underbrace{\forall c \in \mathbb{R}_{>0}}_{\text{Gilt für alle Konstanten } c > 0}, \exists n_0 \in \mathbb{N}, \forall n \geq n_0, 0 \leq f(n) < cg(n)\}$$

In  $\mathcal{O}$ -Notation gilt es für eine Konstante  $c > 0$

## $\omega$ -Notation

- $\omega$ -Notation stellt eine echte untere Schranke dar
- Ausschlaggebend ist, dass es für alle  $c \in \mathbb{R}_{>0}$  gelten muss
- Außerdem  $>$  statt  $\geq$
- z.B.:  $\frac{n^2}{2} = \omega(n)$  und  $\frac{n^2}{2} \neq \omega(n^2)$

$$\omega(g) = \{f : \forall c \in \mathbb{R}_{>0}, \exists n_0 \in \mathbb{N} \forall n \geq n_0, 0 \leq cg(n) < f(n)\}$$

## 1.8 Insertion Sort (Sortieren durch Einfügen)

### Idee – Insertion-Sort

- Halte die linke Teilfolge sortiert
- Füge nächsten Schlüsselwert hinzu, indem es an die korrekte Position eingefügt wird
- Wiederhole den Vorgang bis Teilfolge aus der gesamten Liste besteht

### Code

#### Insertion-Sort(A)

```
1 FOR j = 1 TO A.length - 1
2   key = A[j]
3   // Füge A[j] in die sortierte Sequenz A[0...j-1] ein
4   i = j - 1
5   WHILE i >= 0 and A[i] > key
6     A[i + 1] = A[i]
7     i = i - 1
8   A[i + 1] = key
```

### Schleifeninvariante von Insertion Sort

- Zu Beginn jeder Iteration der for-Schleife besteht die Teilfolge  $A[0 \dots j-1]$  aus den Elementen der ursprünglichen Teilfolge  $A[0 \dots j-1]$  enthaltenen Elementen, allerdings in sortierter Reihenfolge.

### Korrektheit von Insertion Sort

**Initialisierung** Beginn mit  $j=1$ , also Teilfeld  $A[0 \dots j-1]$  besteht nur aus einem Element  $A[0]$ . Dies ist auch das ursprüngliche Element und Teilfeld ist sortiert.

**Fortsetzung** Zu zeigen ist, dass die Invariante bei jeder Iteration erhalten bleibt. Ausführungsblock der for-Schleife sorgt dafür, dass  $A[j-1]$ ,  $A[j-2]$ ,... je um Stelle nach rechts geschoben werden bis  $A[j]$  korrekt eingefügt wurde. Teilfeld  $A[0 \dots j]$  besteht aus ursprünglichen Elementen und ist sortiert. Inkrementieren von  $j$  erhält die Invariante.

**Terminierung** Abbruchbedingung der for-Schleife, wenn  $j > A.length - 1$ . Jede Iteration erhöht  $j$ . Dann bei Abbruch ist  $j = n$  und einsetzen in Invariante liefert das Teilfeld  $A[0 \dots n-1]$  welches aus den ursprünglichen Elementen besteht und sortiert ist. Teilfeld ist gesamtes Feld.

⇒ Algorithmus Insertion Sort arbeitet damit korrekt.



## Laufzeitanalyse von Insertion Sort

Zeile	Kosten	Anzahl
1	$c_1$	$n$
2	$c_2$	$n - 1$
3	0	$n - 1$
4	$c_4$	$n - 1$
5	$c_5$	$\sum_{j=1}^{n-1} t_j$
6	$c_6$	$\sum_{j=1}^{n-1} (t_j - 1)$
7	$c_7$	$\sum_{j=1}^{n-1} (t_j - 1)$
8	$c_8$	$n - 1$

- Festlegung der Laufzeit für jede Zeile
- Jede Zeile besitzt gewissen Kosten  $c_i$
- Jede Zeile wird  $x$  mal durchgeführt
- $Laufzeit = Anzahl * Kosten$  jeder Zeile
- Schleifen: Abbruchüberprüfung zählt auch
- $t_j$ : Anzahl der Abfragen der While-Schleife
- Laufzeit:  $T(n) = c_1 n + c_2(n - 1) + c_4(n - 1) + c_5 \sum_{j=1}^{n-1} t_j + c_6 \sum_{j=1}^{n-1} (t_j - 1) + c_7 \sum_{j=1}^{n-1} (t_j - 1) + c_8(n - 1)$

- Warum  $n$  in Zeile 1?
- Die Überprüfung der Fortführungsbedingung beinhaltet auch die letzte Überprüfung
  - Quasi die Überprüfung, durch die die Schleife abbricht

- Warum  $\sum_{j=1}^{n-1}$  in Zeile 5?
- Aufsummierung aller einzelnen  $t_j$  über die Anzahl der Schleifendurchläufe
  - Diese ist allerdings  $n - 1$  und nicht  $n$ , da die Abbruchüberprüfung dort auch enthalten ist

- Warum  $t_j - 1$  in Zeile 6?
- Selbes Argument wie oben, bei  $t_j$  ist die Abbruchüberprüfung enthalten
  - Deswegen wird die while-Schleife nur  $t_j - 1$ -mal ausgeführt

- Best Case
- zu sortierendes Feld ist bereits sortiert
  - $t_j$  wird dadurch zu 1, da die While-Schleife immer nur einmal prüft (Abbruch)
  - Die zwei Zeilen innerhalb der While-Schleife werden nie ausgeführt
  - Durch Umformen ergibt sich, dass die Laufzeit eine lineare Funktion in  $n$  ist

- Worst Case
- zu sortierendes Feld ist umgekehrt sortiert
  - $t_j$  wird dadurch zu  $j + 1$ , da die While-Schleife immer die gesamte Länge prüft
  - Durch Umformen ergibt sich, dass die Laufzeit eine quadratische Funktion in  $n$  ist ( $n^2$ )

- Average Case
- im Mittel gut gemischt
  - $t_j$  wird dadurch zu  $j/2$
  - Die Laufzeit bleibt aber eine quadratische Funktion in  $n$  ( $n^2$ )

## Asymptotische Laufzeitbetrachtung $\Theta$

- $T(n)$  lässt sich als quadratische Funktion  $an^2 + bn + c$  betrachten
- Terme niedriger Ordnung sind für große  $n$  irrelevant
- Deswegen Vereinfachung zu  $n^2$  und damit  $\Theta(n^2)$

## 1.9 Bubble Sort

### Idee – Bubble Sort

- Vergleiche Paare von benachbarten Schlüsselwerten
- Tausche das Paar, falls rechter Schlüsselwert kleiner als linker

### Code

#### BubbleSort(A)

```
1 FOR i = 0 TO A.length - 2
2   FOR j = A.length - 1 DOWNTO i + 1
3     IF A[j] < A[j-1]
4       SWAP(A[j], A[j-1])
```

### Analyse von Bubble Sort

- Anzahl der Vergleiche
- Es werden stets alle Elemente der Teilfolge miteinander verglichen
  - Unabhängig von der Vorsortierung sind Worst und Best Case identisch

- Anzahl der Vertauschungen
- Best Case: 0 Vertauschungen
  - Worst Case:  $\frac{n^2-n}{2}$  Vertauschungen

- Komplexität
- Best Case:  $\Theta(n)$
  - Average Case:  $\Theta(n^2)$
  - Worst Case:  $\Theta(n^2)$

## 1.10 Selection Sort

### Idee – Selection Sort

- Sortieren durch direktes Auswählen
- MinSort: "wähle kleines Element in Array und tausche es nach vorne"
- MaxSort: "wähle größtes Element in Array und tausche es nach vorne"

### Code (MinSort)

#### Selection-Sort(A)

```
1 FOR i = 0 TO A.length - 2
2   k = i
3   FOR j = i + 1 TO A.length - 1
4     IF A[j] < A[k]
5       k = j
6   SWAP(A[i], A[k])
```

---

## 1.11 Divide-And-Conquer Prinzip

---

### Idee — Divide-And-Conquer

Zerlege das Problem und löse es direkt oder zerlege es weiter:

- |         |   |
|---------|---|
| Divide  | <ul style="list-style-type: none"><li>• Teile das Problem in mehrere Teilprobleme auf</li><li>• Teilprobleme sind Instanzen des gleichen Problems</li></ul> |
| Conquer | <ul style="list-style-type: none"><li>• Beherrsche die Teilprobleme rekursiv</li><li>• Falls Teilprobleme klein genug, löse sie auf direktem Weg</li></ul>  |
| Combine | <ul style="list-style-type: none"><li>• Vereine die Lösungen der Teilprobleme zu Lösung des ursprünglichen Problems</li></ul>                               |
- Anderer Ansatz im Gegensatz zu z.B. `InsertionSort` (inkrementelle Herangehensweise)
  - Laufzeit ist im schlechtesten Fall immer noch besser als `InsertionSort`

## 1.12 Merge Sort

### Idee – Merge Sort

- *Divide*: Teile die Folge aus  $n$  Elementen in zwei Teilfolgen von je  $\frac{n}{2}$  Elemente auf
- *Conquer*: Sortiere die zwei Teilfolgen rekursiv mithilfe von MergeSort
- *Combine*: Vereinige die zwei sortierten Teilfolgen, um die sortierte Lösung zu erzeugen

### Code

#### MERGE-SORT(A,p,r)

```
1 IF p < r
2   q = ⌊(p+r)/2⌋           // Teilen in 2 Teilfolgen
3   MERGE-SORT(A, p, q)     // Sortieren der beiden Teilfolgen
4   MERGE-SORT(A, q+1, r)
5   MERGE(A, p, q, r)      // Vereinigung der beiden sortierten Teilfolgen
```

#### MERGE(A,p,q,r)

```
1 n1 = q - p + 1
2 n2 = r - q
3 Let L[0...n1] and R[0...n2] be new arrays
4 FOR i = 0 TO n1 - 1 // Auffüllen der neu erstellten Arrays
5   L[i] = A[p + i]
6 FOR j = 0 TO n2 - 1
7   R[j] = A[q + j + 1]
8 L[n1] = ∞ // Einfügen des Sentinel-Wertes
9 R[n2] = ∞
10 i = 0
11 j = 0
12 FOR k = p TO r // Eintragweiser Vergleich der Elemente
13   IF L[i] ≤ R[j]
14     A[k] = L[i] // Sortiertes Zurückschreiben in Original-Array
15     i = i + 1
16   ELSE
17     A[k] = R[j]
18     j = j + 1
```

(Teilarrays werden nicht parallel bearbeitet)

### Korrektheit von MergeSort

**Schleifeninvariante** Zu Beginn jeder Iteration der `for`-Schleife (Letztes `for` in Methode `MERGE`) enthält das Teilfeld  $A[p \dots k-1]$  die  $k-p$  kleinsten Elemente aus  $L[0 \dots n_1]$  und  $R[0 \dots n_2]$  in sortierter Reihenfolge. Weiter sind  $L[i]$  und  $R[i]$  die kleinsten Elemente ihrer Arrays, die noch nicht zurück kopiert wurden.

**Initialisierung** Vor der ersten Iteration gilt  $k=p$ . Daher ist  $A[p \dots k-1]$  leer und enthält 0 kleinste Elemente von  $L$  und  $R$ . Wegen  $i=j=0$  sind  $L[i]$  und  $R[i]$  die kleinsten Elemente ihrer Arrays, die noch nicht zurück kopiert wurden.

**Fortsetzung** Müssen zeigen, dass Schleifeninvariante erhalten bleibt. Dafür nehmen wir an, dass  $L[i] \leq R[j]$ . Dann ist  $L[i]$  kleinstes Element, welches noch nicht zurück kopiert wurde. Da Array  $A[p \dots k-1]$  die  $k-p$  kleinsten Elemente enthält, wird der Array  $A[p \dots k]$  die  $k-p+1$  kleinsten Elemente enthalten, nachdem der Wert nach der Durchführung von  $A[k]=L[i]$  kopiert wurde. Die Erhöhung der Variablen  $k$  und  $i$  stellt die Schleifeninvariante für die nächste Iteration wieder her. Wenn  $L[i] > R[j]$  dann analoges Argument in der ELSE-Anweisung.

**Terminierung** Beim Abbruch gilt  $k=r+1$ . Durch die Schleifeninvariante enthält  $A[p \dots r]$  die kleinsten Elemente von  $L[0 \dots n_1]$  und  $R[0 \dots n_2]$  in sortierter Reihenfolge. Alle Elemente außer der Sentinels wurden komplett zurück kopiert. MergeSort ist außerdem ein stabiler Algorithmus.

## Analyse von MergeSort

**Ziel** Bestimme Rekursionsgleichung für Laufzeit  $T(n)$  von  $n$  Zahlen im schlechtesten Fall


**Divide** Berechnung der Mitte des Feldes: Konstante Zeit  $\Theta(1)$

**Conquer** Rekursives Lösen von zwei Teilproblemen der Größe  $\frac{n}{2}$ : Laufzeit von  $2 T(\frac{n}{2})$

**Combine** MERGE auf einem Teilfeld der Länge  $n$ : Lineare Zeit  $\Theta(n)$

$$T(n) = \begin{cases} \Theta(1) & \text{falls } n = 1 \\ 2 T(\frac{n}{2}) + \Theta(n) & \text{falls } n > 1 \end{cases}$$

Lösen der Rekursionsgleichung mithilfe eines Rekursionsbaums



- Verwenden der Konstante  $c$  statt  $\Theta(1)$
- $cn$  stellt den Aufwand an der ersten Ebene dar
- Der addierte Aufwand jeder Stufe (aller Knoten) ist auch  $cn$
- Die Anzahl der Ebenen lässt sich mithilfe von  $\lg(n) + 1$  bestimmen (2-er Logarithmus)
- Damit ergibt sich für die Laufzeit:  $cn \cdot \lg(n) + cn$
- Für  $\lim_{n \rightarrow \infty}$  wird diese zu  $n \cdot \lg(n)$
- Laufzeit beträgt damit  $\Theta(n \cdot \lg(n))$
- Laufzeit von MergeSort ist in jedem Fall gleich

## 1.13 Quicksort

### Idee – Quicksort

**Pivotelement** Wahl eines Pivotelement  $x$  aus dem Array (=Mittelsäule bei Sortierung)

**Divide** Zerlege den Array  $A[p \dots r]$  in zwei Teilarrays  $A[p \dots q-1]$  und  $A[q+1 \dots r]$ , sodass jedes Element von  $A[p \dots q-1]$  kleiner oder gleich  $A[q]$  ist, welches wiederum kleiner oder gleich jedem Element von  $A[q+1 \dots r]$  ist. Berechnen Sie den Index  $q$  als Teil vom Partition Algorithmus.

**Conquer** Sortieren beider Teilarrays  $A[p \dots q-1]$  und  $A[q+1 \dots r]$  durch rekursiven Aufruf von Quicksort.

**Combine** Da die Teilarrays bereits sortiert sind, ist keine weitere Arbeit nötig um diese zu vereinigen.  $A[p \dots r]$  ist nun sortiert.

### Code

#### QUICKSORT(A,p,r)

```
1 IF p < r    // Überprüfung, ob Teilarray leer ist
2   q = PARTITION(A,p,r)
3   QUICKSORT(A,p,q-1)
4   QUICKSORT(A,q+1,r)
```

#### PARTITION(A,p,r)

```
1 x = A[r]    // Wahl des Pivotelements
2 i = p - 1   // Index i setzen
3 FOR j = p TO r - 1 // Auffüllen des Teilarrays mit Elementen
4   IF A[j] ≤ x
5     i = i + 1
6     SWAP(A[i], A[j])
7 SWAP(A[i+1], A[r]) // Tausch des Pivotelements
8 RETURN i + 1 // Neuer Index des Pivotelements
```

(Teilarrays werden nicht parallel bearbeitet)

## Korrektheit von Quicksort

**Schleifeninvariante** Zu Beginn jeder Iteration der `for`-Schleife gilt für den Arrayindex  $k$  folgendes:

1. Ist  $p \leq k \leq i$ , so gilt  $A[k] \leq x$
2. Ist  $i + 1 \leq k \leq j - 1$ , so gilt  $A[k] > x$
3. Ist  $k = r$ , so gilt  $A[k] = x$

**Initialisierung** Vor der ersten Iteration gilt  $i = p - 1$  und  $j = p$ . Da es keine Werte zwischen  $p$  und  $i$  gibt und es auch keine Werte zwischen  $i + 1$  und  $j - 1$  gibt, sind die ersten beiden Eigenschaften trivial erfüllt. Die Zuweisung in  $x = A[r]$  sorgt für die Erfüllung der dritten Eigenschaft.

**Fortsetzung** Zwei mögliche Fälle durch `IF`  $A[j] \leq x$ . Wenn  $A[j] > x$ , dann inkrementiert die Schleife nur den Index  $j$ . Dann gilt Bedingung 2 für  $A[j-1]$  und alle anderen Einträge bleiben unverändert. Wenn  $A[j] \leq x$ , dann wird Index  $i$  inkrementiert und die Einträge  $A[i]$  und  $A[j]$  getauscht und schließlich der Index  $j$  erhöht. Wegen des Vertauschens gilt  $A[i] \leq x$  und Bedingung 1 ist erfüllt. Analog gilt  $A[j-1] > x$ , da das Element welches mit  $A[j-1]$  vertauscht wurde wegen der Invariante gerade größer als  $x$  ist.

**Terminierung** Bei der Terminierung gilt, dass  $j = r$ . Daher gilt, dass jeder Eintrag des Arrays zu einer der drei durch die Invariante beschriebenen Mengen gehört.

## Performanz von Quicksort

- Abhängig von der **Balanciertheit** der Teilarrays
  - Definition Balanciert: ungefähr gleiche Anzahl an Elementen
  - Teilarrays balanciert: Laufzeit asymptotisch so schnell wie `MergeSort`
  - Teilarrays unbalanciert: Laufzeit kann so langsam wie `InsertionSort` laufen
- Zerlegung im **schlechtesten Fall**
  - Partition zerlegt Problem in ein Teilproblem mit  $n - 1$  Elementen und eins mit 0 Elementen
  - Unbalancierte Zerlegung mit Kosten  $\Theta(n)$  zieht sich durch gesamte Rekursion
  - Aufruf auf Feld der Größe 0:  $T() = \Theta(1)$
  - Laufzeit (rekursiv):
    - \*  $T(n) = T(n - 1) + T(0) + \Theta(n) = T(n - 1) + \Theta(n)$
    - \* Insgesamt folgt:  $T(n) = \Theta(n^2)$
- Zerlegung im **besten Fall**
  - Problem wird so balanciert wie möglich zerlegt
  - Zwei Teilprobleme mit maximaler Größe von  $\frac{n}{2}$
  - Zerlegung kostet  $\Theta(n)$
  - Laufzeit (rekursiv):
    - \*  $T(n) \leq 2T(\frac{n}{2}) + \Theta(n)$
    - \* Laufzeit beträgt:  $O(n \lg(n))$
  - Solange die Aufteilung konstant bleibt, bleibt die Laufzeit  $O(n \lg(n))$

---

## 1.14 Laufzeitanalyse von rekursiven Algorithmen

---

### 1.14.1 Analyse von Divide-And-Conquer Algorithmen

---

- $T(n)$  ist Laufzeit eines Problems der Größe  $n$
- Für kleines Problem benötigt die direkte Lösung eine konstante Zeit  $\Theta(1)$
- Für sonstige  $n$  gilt:
  - Aufteilen eines Problems führt zu  $a$  Teilproblemen
  - Jedes dieser Teilprobleme hat die Größe  $\frac{1}{b}$  der Größe des ursprünglichen Problems
  - Lösen eines Teilproblems der Größe  $\frac{n}{b}$ :  $T(\frac{n}{b})$
  - Lösen  $a$  solcher Probleme:  $a T(\frac{n}{b})$
  - $D(n)$ : Zeit um das Problem aufzuteilen (Divide)
  - $C(n)$ : Zeit um Teillösungen zur Gesamtlösung zusammenzufügen (Combine)

$$T(n) = \begin{cases} \Theta(1) & \text{falls } n \leq c \\ a T(\frac{n}{b}) + D(n) + C(n) & \text{sonst} \end{cases}$$

---

### 1.14.2 Substitutionsmethode

---

- Idee: Erraten einer Schranke und Nutzen von Induktion zum Beweis der Korrektheit
- Ablauf:
  1. Rate die Form der Lösung (Scharfes Hinsehen oder kurze Eingaben ausprobieren/einsetzen)
  2. Anwendung von vollständiger Induktion zum Finden der Konstanten und Beweis der Lösung



## Beispiel

Betrachten von  
MergeSort

- $T(1) \leq c$
- $T(n) \leq T(\lfloor \frac{n}{2} \rfloor) + T(\lceil \frac{n}{2} \rceil) + cn$

Ziel

Obere Abschätzung  $T(n) \leq g(n)$  mit  $g(n)$  ist eine Funktion, die durch eine geschlossene Formel dargestellt werden kann.

Wir "raten":  $T(n) \leq 4cn \lg(n)$  und nehmen dies für alle  $n' < n$  an und zeigen es für  $n$ .

Induktion

- $\lg$  steht hier für  $\log_2$
- $n = 1: T(1) \leq c$
- $n = 2: T(2) \leq T(1) + T(1) + 2c$   
 $\leq 4c \leq 8c$   
 $T(2) = 4c * 2 \lg(2) = 8c$

Hilfsbehauptungen

- (1):  $\lfloor \frac{n}{2} \rfloor + \lceil \frac{n}{2} \rceil = n$
- (2):  $\lfloor \frac{n}{2} \rfloor \leq \frac{n}{2} \leq \frac{2}{3}n$
- (3):  $\log_c(\frac{a}{b}) = \log_c(a) - \log_c(b)$
- (4):  $\log_c(a * b) = \log_c(a) + \log_c(b)$

Induktionsschritt

- Annahme:  $n > 2$  und sei Behauptung wahr für alle  $n' < n$ .

$$\begin{aligned} T(n) &\leq T(\lfloor \frac{n}{2} \rfloor) + T(\lceil \frac{n}{2} \rceil) + cn \\ &\leq 4c \lfloor \frac{n}{2} \rfloor \lg(\lfloor \frac{n}{2} \rfloor) + 4c \lceil \frac{n}{2} \rceil \lg(\lceil \frac{n}{2} \rceil) + cn \\ \text{(HB)} &\leq 4c \cdot \lg(\frac{2}{3}n) \cdot (\lfloor \frac{n}{2} \rfloor + \lceil \frac{n}{2} \rceil) + cn \\ &\leq 4c \cdot \lg(\frac{2}{3}n) \cdot n + cn \\ \text{(HB)} &\leq 4cn \cdot (\lg(\frac{2}{3}) + \lg(n)) + cn \\ &= 4cn \cdot \lg(n) + 4cn \cdot \lg(\frac{2}{3}) \\ &= 4cn \cdot \lg(n) + cn(1 + 4 \cdot (\lg(2) - \lg(3))) \\ &\leq 4cn \cdot \lg(n) \\ &\Rightarrow \Theta(n \lg(n)) \end{aligned}$$

### 1.14.3 Rekursionsbaum

#### Idee – Rekursionsbaum

Stellen das Ineinander-Einsetzen als Baum dar und Analyse der Kosten.

Ablauf:

1. Jeder Knoten stellt die Kosten eines Teilproblems dar
  - Die Wurzel stellt die zu analysierenden Kosten  $T(n)$  dar
  - Die Blätter stellen die Kosten der Basisfälle dar (z.B.  $T(0)$ )
2. Berechnen der Kosten innerhalb jeder Ebene des Baums
3. Die Gesamtkosten sind die Summe über die Kosten aller Ebenen

Rekursionsbaum ist nützlich um Lösung für Substitutionsmethode zu erraten

### Beispiel

$$T(n) = 3T(\lfloor \frac{n}{4} \rfloor) + \Theta(n^2)$$

Vorüberlegungen

- $\Rightarrow T(n) = 3T(\frac{n}{4}) + cn^2$  ( $c > 0$ )
- Je Abstieg verringert sich die Größe des Problems um den Faktor 4.
- Erreichen der Randbedingung ist vonnöten, die Frage ist wann dies geschieht.
- Größe Teilproblem bei Level  $i$ :  $\frac{n}{4^i}$
- Erreichen Teilproblem der Größe 1, wenn  $\frac{n}{4^i} = 1$ , d.h. wenn  $i = \log_4(n)$   
 $\Rightarrow$  Baum hat also  $\log_4 n + 1$  Ebenen

Kosten pro Ebene

- Jede Ebene hat 3-mal so viele Knoten wie darüber liegende
- Anzahl der Knoten in Tiefe  $i$  ist  $3^i$
- Kosten  $c(\frac{n}{4^i})^2$ ,  $i = 0, \dots, \log_4 n - 1$
- Anzahl  $\cdot$  Kosten  $= 3^i \cdot c(\frac{n}{4^i})^2 = (\frac{3}{16})^i \cdot cn^2$

Unterste Ebene

- $3^{\log_4(n)} = n \log_4(3)$  Knoten
- Jeder Knoten trägt  $T(1)$  Kosten bei
- Kosten unten:  $n^{\log_4(3)} \cdot T(1) = \Theta(n^{\log_4(3)})$

Addiere alle Kosten aller Ebenen

$$\begin{aligned} T(n) &= cn^2 + \frac{3}{16}cn^2 + (\frac{3}{16})^2cn^2 + \dots + (\frac{3}{16})^{\log_4 n - 1}cn^2 + \Theta(n^{\log_4(3)}) \\ &= \sum_{i=0}^{\log_4 n - 1} (\frac{3}{16})^i cn^2 + \Theta(n^{\log_4(3)}) \\ &= \frac{(\frac{3}{16})^{\log_4 n} - 1}{\frac{3}{16} - 1} \cdot cn^2 + \Theta(n^{\log_4(3)}) \end{aligned}$$

- Verwendung einer unendlichen fallenden geometrischen Reihe als obere Schranke:

$$\begin{aligned} T(n) &= \sum_{i=0}^{-1} (\frac{3}{16})^i \cdot cn^2 + \Theta(n^{\log_4(3)}) \\ &< \sum_{i=0}^{\infty} (\frac{3}{16})^i \cdot cn^2 + \Theta(n^{\log_4(3)}) \\ &= \frac{1}{1 - \frac{3}{16}} \cdot cn^2 + \Theta(n^{\log_4(3)}) \\ &= \frac{16}{13} \cdot cn^2 + \Theta(n^{\log_4(3)}) = O(n^2) \end{aligned}$$

Jetzt

Substitutionsmethode

Zu zeigen  $\exists d > 0 : T(n) \leq dn^2$

Induktionsanfang  $T(n) = 3 \cdot T(\lfloor \frac{1}{4} \rfloor) + c \cdot 1^2$

$$= 3 \cdot T(0) + c = c$$

Induktionsschritt  $T(n) \leq 3 \cdot T(\lfloor \frac{n}{4} \rfloor) + cn^2$

$$\begin{aligned} &\leq 3 \cdot d(\lfloor \frac{n}{4} \rfloor)^2 + cn^2 \\ &\leq 3d(\frac{n}{4})^2 + cn^2 \\ &= \frac{3}{16}dn^2 + cn^2 \\ &\leq dn^2, \text{ falls } d \geq \frac{16}{13}c \end{aligned}$$

#### 1.14.4 Mastertheorem

##### Idee – Mastertheorem

Seien  $a \geq 1$  und  $b > 1$  Konstanten. Sei  $f(n)$  eine positive Funktion und  $T(n)$  über den nichtnegativen ganzen Zahlen über die Rekursionsgleichung  $T(n) = a T(\frac{n}{b}) + f(n)$  definiert, wobei wir  $\frac{n}{b}$  so interpretieren, dass damit entweder  $\lfloor \frac{n}{b} \rfloor$  oder  $\lceil \frac{n}{b} \rceil$  gemeint ist. Dann besitzt  $T(n)$  die folgenden asymptotischen Schranken ( $a$  und  $b$  werden aus  $f(n)$  gelesen):

1. Gilt  $f(n) = O(n^{\log_b(a-\epsilon)})$  für eine Konstante  $\epsilon > 0$ , dann  $T(n) = \Theta(n^{\log_b(a)})$
2. Gilt  $f(n) = \Theta(n^{\log_b(a)})$ , dann gilt  $T(n) = \Theta(n^{\log_b(a)} \lg(n))$
3. Gilt  $f(n) = \Omega(n^{\log_b(a+\epsilon)})$  für eine Konstante  $\epsilon > 0$  und  $a f(\frac{n}{b}) \leq c f(n)$  für eine Konstante  $c < 1$  und hinreichend großen  $n$ , dann ist  $T(n) = \Theta(f(n))$

##### Erklärung

- In jedem der 3 Fälle wird die Funktion  $f(n)$  mit  $n^{\log_b(a)}$  verglichen
  1. Wenn  $f(n)$  polynomial kleiner ist als  $n^{\log_b(a)}$ , dann  $T(n) = \Theta(n^{\log_b(a)})$
  2. Wenn  $f(n)$  und  $n^{\log_b(a)}$  die gleiche Größe haben, gilt  $T(n) = \Theta(n^{\log_b(a)} \lg(n))$
  3. Wenn  $f(n)$  polynomial größer als  $n^{\log_b(a)}$  und  $a f(\frac{n}{b}) \leq c f(n)$  erfüllt, dann  $T(n) = \Theta(f(n))$
- (polynomial größer/kleiner: um Faktor  $n^\epsilon$  asymptotisch größer/kleiner)

##### Nicht abgedeckte Fälle

- Wenn einer dieser Fälle eintritt, kann das Mastertheorem nicht angewendet werden
  1. Wenn  $f(n)$  kleiner ist als  $n^{\log_b(a)}$ , aber nicht polynomial kleiner
  2. Wenn  $f(n)$  größer ist als  $n^{\log_b(a)}$ , aber nicht polynomial größer
  3. Regularitätsbedingung  $a f(\frac{n}{b}) \leq c f(n)$  wird nicht erfüllt
  4.  $a$  oder  $b$  sind nicht konstant (z.B.  $a = 2^n$ )

## Beispiel

- $T(n) = 9T(\frac{n}{3}) + n$ 
  - $a = 9, b = 3, f(n) = n$
  - $\log_b(a) = \log_3(9) = 2$
  - $f(n) = n = O(n^{\log_b(a-\epsilon)})$   
 $= O(n^{2-\epsilon})$
  - Ist diese Gleichung für ein  $\epsilon > 0$  erfüllt?  $\Rightarrow \epsilon = 1$
  - **1. Fall**  $\Rightarrow T(n) = \Theta(n^2)$
- $T(n) = T(\frac{2n}{3}) + 1$ 
  - $a = 1, b = \frac{3}{2}, f(n) = 1$
  - $\log_{\frac{3}{2}} 1 = 0$
  - $f(n) = 1 = O(n^{\log_b(a)})$   
 $= O(n^0)$   
 $= O(1)$
  - **2. Fall**  $\Rightarrow T(n) = \Theta(1 * \lg(n)) = \Theta(\lg(n))$
- $T(n) = 3(T\frac{n}{4}) + n \lg(n)$ 
  - $a = 3, b = 4, f(n) = n \lg(n)$
  - $n^{\log_b(a)} = n^{\log_4(3)} \leq n^{0.793}$
  - $\epsilon = 0.1$  im Folgenden
  - $f(n) = n \lg(n) \geq n \geq n^{0.793+0.1} \geq n^{0.793}$
  - **3. Fall**  $\Rightarrow f(n) = \Omega(n^{\log_b(a+0.1)})$
  - $af(\frac{n}{b}) = 3f(\frac{n}{4}) = 3(\frac{n}{4}) \lg(\frac{n}{4}) \leq \frac{3}{4}n \lg(n)$
  - Damit ist auch die Randbedingung erfüllt und  $T(n) = \Theta(n \lg(n))$

Grundlegende Datenstrukturen	Fortgeschrittene Datenstrukturen	Randomisierte Datenstrukturen
Stacks	Rot-Schwarz-Bäume	Skip Lists
Verkettete Listen	AVL-Bäume	Hash Tables
Queues	Splay-Bäume	Bloom-Filter
Bäume	Heaps	
Binäre Suchbäume	B-Bäume	

TABELLE 3: Übersicht Datenstrukturen